
Madár Patrik

Markov-láncok

Folyamatosan frissülő jegyzet

Budapest, 2026

Tartalomjegyzék

1. Fogalmak	3
1.1. Markov-láncok bevezetése	3
1.2. Rejtett Markov-modell	5
2. Rejtett Markov-modell becslése	6
2.1. Expectation-Maximization algoritmus	6
2.2. Bayes-filter	8
2.3. Bayes-filter konvergenciája	9
3. Diszkrét állapotterű rejtett Markov-modell	12
3.1. Forward-Backward algoritmus	12
3.2. Baum-Welch algoritmus	15
4. Folytonos állapotterű rejtett Markov-modell	17
4.1. Kalman-szűrő	17
4.2. Kiterjesztett Kalman-szűrő (EKF)	18
4.3. σ -pontos Kalman-szűrő (UKF)	19

1. fejezet

Fogalmak

1.1. Markov-láncok bevezetése

1.1.1. Definíció. Legyen adott elemi események Ω halmazán értelmezett A σ -algebra. Ekkor (Ω, A) -t mérhető térnek, és $\mu : A \rightarrow [0; \infty]$ -t mértéknek nevezzük, ha $\mu(\emptyset) = 0$ és diszjunkt $A_i \in A$ -kra

$$\mu\left(\bigcup A_i\right) = \sum \mu(A_i),$$

végül az (Ω, A, μ) rendezett hármast mértéktérnek nevezzük.

1.1.2. Definíció. Azt a legszűkebb σ -algebrát, ami tartalmazza $\mathbb{R}$ nyílt részhalmazait, Borel-mérhető halmazok rendszerének nevezzük, melynek elemei a Borel-mérhető halmazok (ha az alaphalmaz nem $\mathbb{R}$, akkor az adott topologikus tér nyílt halmazait tartalmazó legszűkebb σ -algebra).

1.1.3. Definíció. (Ω, A) mérhető téren értelmezett $f : \Omega \rightarrow \mathbb{R}$ függvény mérhető függvény, ha $\forall \mathbb{R}$ -ben Borel-mérhető halmaz f általi ösképe mérhető, azaz $\in A$. Ha $P : A \rightarrow [0; 1]$ mérték, melyre $P(\Omega) = 1$, akkor az (Ω, A, P) hármast valószínűségi mezőnek nevezzük.

1.1.4. Definíció. (Ω, A, P) valószínűségi mező Ω eseményterén értelmezett $X : \Omega \rightarrow \mathbb{R}$ függvény valószínűségi változó (ez a hivatalos definíció), ha $\forall x \in \mathbb{R}$ -re

$$\{\omega \in \Omega : X(\omega) \leq x\} \in A$$

1.1.5. Megjegyzés. Általában valós/vektorértékű valószínűségi változón egy (Ω, A, P) valószínűségi mezőn definiált $(\mathbb{R}^n, \mathbb{B}^n)$ értékű mérhető függvényt értünk, ahol $\mathbb{B}^n$ az $\mathbb{R}^n$ -ben Borel-mérhető halmazok σ -algebrája. Külön kikötés hiányában I halmaz Borel-halmazait $\mathbb{B}_I$ vagy $\mathbb{B}$ jelöli (utóbbi csak akkor, ha a jelölés egyértelmű).

1.1.6. Definíció. Az (Ω, A, P) valószínűségi mezőn értelmezett X valószínűségi változó eloszlásfüggvénye $F_X : \mathbb{R} \rightarrow \mathbb{R}$, $F_X(x) = P(X < x)$. $f : \mathbb{R} \rightarrow \mathbb{R}$ az X abszolút folytonos valószínűségi változó sűrűségfüggvénye, ha $F_X(x) = \int_{-\infty}^x f(t)dt$.

1.1.7. Definíció. Az (Ω, A, P) valószínűségi mezőn és annak T időhalmazán értelmezett

$$X(t, \omega) : T \times \Omega \rightarrow \mathbb{R}$$

kétváltozós függvény **sztochasztikus folyamat**, ha $\forall$ rögzített $t \in T$ -re $X(t, \omega)$ az (Ω, A, P) valószínűségi mezőn értelmezett valószínűségi változó. Az $X(t; \omega)$ a $T = \mathbb{N}$ esetben diszkrét idejű, $T = [0; \infty)$ esetben folytonos idejű sztochasztikus folyamat. Rögzített $\omega_0 \in \Omega$ -ra

$$X(t, \omega_0) : T \rightarrow \mathbb{R}$$

az $X(t; \omega) : T \times \Omega \rightarrow \mathbb{R}$ sztochasztikus folyamat ω_0 kimenetel melletti **trajektóriája**.

1.1.8. Definíció.

$$X(n; \omega) = X_n(\omega) : \mathbb{N} \times \Omega \rightarrow I$$

diszkrét idejű sztochasztikus folyamat (diszkrét idejű) **Markov-lánc/Markov-folyamat**, ha **Markov-tulajdonságú**, azaz

$$A_n = \sigma(X_0, X_1, \dots, X_n)$$

esetén $\forall B \in \mathbb{B}_I, \forall m \geq n$ -re

$$P(X_m \in B | X_0, X_1, \dots, X_n) = P(X_m \in B | A_n) = P(X_m \in B | X_n)$$

1.1.9. Definíció.

$$X_t(\omega) = X(t; \omega) : [0, \infty] \times \Omega \rightarrow I$$

folytonos idejű sztochasztikus folyamat (folytonos idejű) **Markov-folyamat**, ha **Markov-tulajdonságú**, azaz

$$A_{t_0} = \sigma(\{X_t\}_{t \leq t_0})$$

esetén $\forall B \in \mathbb{B}_I, \forall t_1 \geq t_0$ -ra

$$P(X_{t_1} \in B | A_{t_0}) = P(X_{t_1} \in B | X_{t_0})$$

1.1.10. Definíció. $(X_n)_n$ Markov-lánc homogén/stacionárius, ha a $P(X_{n+1} = j | X_n = i)$ feltételes valószínűség minden n -re ugyanannyi, ekkor előbbi valószínűségekre a p_{ij} jelölést használjuk.

1.1.11. Definíció. Legyen adott egy $(X_n)_n$ diszkrét idejű homogén Markov lánc. Ekkor a

$$P = (p_{ij})_{i,j \in I}$$

mátrix a

$$p_{ij} = P(X_{n+1} = j | X_n = i)$$

egylépéses átmenetvalószínűségek mátrixa.

1.1.12. Megjegyzés. Előfordulhat, hogy $|I|$ megszámlálhatóan végtelen; ekkor szintén a mátrix megnevezést használjuk.

X_0 valószínűségi eloszlása a kezdeti eloszlás. X_0 -nak $\mu = (\mu_i)_{i \in I}$ eloszlására a Markov-tulajdonság miatt

$$\begin{aligned} & P(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) \\ &= P(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdot P(X_0 = i_1, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \\ &= P(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdot \\ &\cdot P(X_{n-1} = i_{n-1} | X_0 = i_0, X_1 = i_1, \dots, X_{n-2} = i_{n-2}) \cdot \dots \cdot P(X_1 = i_1 | X_0 = i_0) \cdot P(X_0 = i_0) \\ &= p_{i_{n-1}i_n} \cdot \dots \cdot p_{i_0i_1} \cdot \mu_{i_0} \end{aligned}$$

Tehát a kezdeti eloszlás és az átmenetmátrix meghatározza a Markov-láncot.

Legyen $m \in \mathbb{N}^+$ tetszőleges, jelölje $p_{ij}^{(n)} = P(X_{n+m} = j | X_n = i)$ az n -lépéses átmenetvalószínűségeket (ezek a homogenitás miatt m -től függetlenek).

1.1.13. Állítás. (*Chapman-Kolmogorov egyenlőség*):

$$p_{ij}^{(n+m)} = \sum_{k \in I} p_{ik}^{(n)} \cdot p_{kj}^{(m)}$$

Bizonyítás. $P(X_{n+m} = j, X_n = k) = P(X_n = k) \cdot P(X_{n+m} = j | X_n = k)$ miatt

$$\begin{aligned} P(X_{n+m} = j | X_0 = i) &= \sum_{k \in I} P(X_{n+m} = j, X_n = k | X_0 = i) \\ &= \sum_{k \in I} P(X_n = k | X_0 = i) \cdot P(X_{n+m} = j | X_n = k, X_0 = i) = \sum_{k \in I} p_{ik}^{(n)} \cdot p_{kj}^{(m)} \end{aligned}$$

□

1.1.14. Következmény. $P^n = (p_{ij}^{(n)})_{i,j \in I}$, vagyis az n -lépéses átmenetvalószínűségek mátrixa éppen P^n .

1.2. Rejtett Markov-modell

1.2.1. Definíció. Legyen $X_n = X(n, \omega_X)$ diszkrét idejű Markov-lánc, $Y_n = Y(n, \omega_Y)$ diszkrét idejű sztochasztikus folyamat. Ekkor (X_n, Y_n) sorozat (rejtett) **Markov-modell**, ha $\forall n$ -re $\forall x_1, \dots, x_n$ -re $\forall A$ Borel-halmazra

$$P(Y_n \in A | X_1 = x_1, \dots, X_n = x_n) = P(Y_n \in A | X_n = x_n)$$

1.2.2. Definíció. Legyen $X_t = X(t, \omega_X)$ folytonos idejű Markov-lánc, $Y_t = Y(t, \omega_Y)$ folytonos idejű sztochasztikus folyamat. Ekkor $(X_t, Y_t)_{t \geq 0}$ (rejtett) **Markov-modell**, ha $\forall t_0 \in [0, \infty)$ -re $\forall A \in B(I_Y)$ Borel-halmazra

$$P(Y_{t_0} \in A | \sigma(\{X_t : t \leq t_0\})) = P(Y_{t_0} \in A | \sigma(X_{t_0}))$$

Gyakorlatban X_n viselkedése nem közvetlenül megfigyelhető (ezért rejtett), emiatt szükségünk van annak becslésére; diszkrét esetben a feladatot érdemes irányított gráfként ábrázolni, ahol a két pontosztály az X_n -ek és az Y_n -ek, ahol $\forall X_n$ -ből $\forall X_m$ -be vezet él $P(X_n \rightarrow X_m)$ súlyozással, továbbá $\forall Y_k$ -ba $P(Y_k | X_n)$ súlyozással ($n, m, k \in \mathbb{N}^+$ tetszőleges), felvéve egy Start csúcsot, melyből X_n -ekbe vezet él a kezdeti eloszlásnak megfelelően.

Az X_n -ek becslésére itt bemutatott módszer megköveteli az eloszlások típusának ismeretét.

1.2.3. Definíció (Utólagos valószínűség). Legyen X egy rejtett (nem közvetlenül megfigyelhető) állapot, és Y egy megfigyelés. Ekkor a

$$P(X = x | Y = y)$$

feltételes valószínűséget **utólagos valószínűségnek** (posterior probability) nevezzük. Az utólagos valószínűség azt fejezi ki, hogy a megfigyelés ismeretében mennyire valószínű az adott rejtett állapot.

A Bayes-tétel segítségével az utólagos valószínűség kiszámítható:

$$P(X = x | Y = y) = \frac{P(Y = y | X = x) \cdot P(X = x)}{P(Y = y)}$$

ahol:

- $P(X = x)$ a **prior** (előzetes) valószínűség,
- $P(Y = y | X = x)$ a **likelihood** (valószínűségi függvény),
- $P(Y = y)$ a **normalizáló tényező**.

2. fejezet

Rejtett Markov-modell becslése

2.1. Expectation-Maximization algoritmus

Gyakorlatban sokszor az eloszlás bonyolult formája miatt nehéz ML-becslést adni egy rejtett Markov-modellhez tartozó eloszlás paraméterére, ezért azt közelítenünk kell. Egy lehetséges közelítés megadására szolgál a következő algoritmus:

Legyen adott egy (diszkrét idejű) $(X_n, Y_n)_{(1 \leq n \leq m)}$ rejtett Markov-modell, a megfigyelések $y = (y_1, \dots, y_m)$, azokhoz tartozó rejtett állapotok $x = (x_1, \dots, x_m)$, az eloszlás

$$(X, Y) \sim p((x, y)|\theta) = p_\theta(x, y) = \exp(\eta(\theta) \cdot s(x, y)) \cdot h(x, y)/c(\theta),$$

ahol η monoton függvény, $\Theta \subseteq \mathbb{R}^n$ nyílt halmaz a vizsgált eloszlástípus lehetséges paramétereinek halmaza,

$$s : \mathbb{R}^d \rightarrow \mathbb{R}^k$$

elégséges statisztika,

$$h : \mathbb{R}^d \rightarrow \mathbb{R}^{\geq 0},$$

$$c : \Theta \rightarrow \mathbb{R}^{\geq 0}$$

normalizáló függvény. Tehát

$$c(\theta) = \int_{(X,Y)} (\exp(\eta(\theta) \cdot s(x, y)) \cdot h(x, y)) d(x, y)$$

Célunk egy $\theta_{MLE} \in \Theta$ megadása, melyre

$$\theta_{MLE} \in \arg \max_{\theta} (p_\theta(y)),$$

vagyis maximalizálja a

$$p(\theta) = p_\theta(y) = \int p_\theta(x, y) dx$$

peremeloszlás likelihood-függvényét (legalábbis elég jól közelíti egy globális maximum-helyét). Feltehető tehát, hogy $\eta(\theta) = \theta$.

2.1.1. Állítás. $\nabla \log(c(\theta)) = \mathbb{E}_\theta s(x, y)$

Bizonyítás. $\forall j$ -re

$$\begin{aligned} (\partial/\partial\theta_j) \log(c(\theta)) &= \frac{1}{c(\theta)} \cdot (\partial/\partial\theta_j) c(\theta) \\ &= \frac{1}{c(\theta)} \int s_j(x, y) p_\theta(x, y) d(x, y) = \mathbb{E}_\theta s_j(x, y) \end{aligned}$$

(feltettük hogy a deriválás és az integrálás felcserélhető)

□

2.1.2. Következmény. θ a likelihood függvény szélsőértéke

$$\Rightarrow \mathbb{E}_\theta(s(X, Y)|Y = y) = \mathbb{E}_\theta(s(X, Y))$$

Bizonyítás.

$$\begin{aligned} 0 &= (\partial/\partial\theta_i) \log(p_\theta(y)) = \frac{1}{p(\theta)} \cdot \int (\partial/\partial\theta_i) p_\theta(x, y) dx \\ &= \frac{1}{p(\theta)} \cdot \int (\partial/\partial\theta_i) \exp(\theta s(x, y) - \log(c(\theta))) \cdot h(x, y) dx \\ &= \frac{1}{p(\theta)} \cdot \int (s_i(x, y) - (\partial/\partial\theta_i) \log(c(\theta))) \cdot p_\theta(x, y) \\ &= \frac{1}{p(\theta)} \cdot \int (s_i(x, y) - \mathbb{E}_\theta s_i(X, Y)) \cdot p_\theta(x, y) \\ &= \int s_i(x, y) \cdot p_\theta(x|y) - \mathbb{E}_\theta s_i(X, Y) \\ &= \mathbb{E}_\theta(s_i(X, Y)|Y = y) - \mathbb{E}_\theta s_i(X, Y) \iff \mathbb{E}_\theta(s(X, Y)|Y = y) = \mathbb{E}_\theta(s(X, Y)) \end{aligned}$$

□

Legyen $\forall t$ -re

$$Q(\theta|\theta_t) = \mathbb{E}_{\theta_t}(\log(p_\theta(X, Y))|Y = y)$$

Az algoritmus ötlete, hogy kiindulunk tetszőleges $\theta_0 \in \Theta$ becslésből és minden iterációban javítunk rajta úgy, hogy megoldjuk a

$$\theta_{t+1} = \arg \max_{\theta} Q(\theta|\theta_t)$$

rekurziót. Vegyük észre, hogy 2.1.1 miatt

$$\begin{aligned} \nabla Q(\theta|\theta_t) &= \nabla(\theta \cdot \mathbb{E}_{\theta_t}(s(X, Y)|Y = y) - \log(c(\theta)) - \text{konstans}) \\ &= \mathbb{E}_{\theta_t}(s(X, Y)|Y = y) - \mathbb{E}_\theta(s(X, Y)) \end{aligned}$$

Az eredeti rekurzió megoldásához tehát megoldandó az

$$\mathbb{E}_{\theta_{t-1}}(s(X, Y)|Y = y) = \mathbb{E}_{\theta_t}(s(X, Y))$$

rekurzió.

Konyhaszabály: addig iteráljuk, mígnem rögzített t -re $\mathbb{E}_{\theta_t}(s(X, Y)|Y = y)$ és $\mathbb{E}_{\theta_t}(s(X, Y))$ majdnem egyenlő (mondjuk az eltérésük $< 10^{-5}$), ekkor ugyanis a becslés előbbi következmény miatt közelít egy szélsőértékhez. A konvergencia abból adódik, hogy a θ_t -khez tartozó értékekből alkotott sorozat monoton és korlátos, márpedig az

$$\mathbb{E}_{\theta_{t-1}}(s(X, Y)|Y = y) = \mathbb{E}_{\theta_t}(s(X, Y))$$

rekurzió miatt és mert

$$Q(\theta|\theta_t) = \mathbb{E}_{\theta_t}(\log(p_\theta(X, Y))|Y = y)$$

sorozat konvergens, adódik, hogy $\exists t$: $\mathbb{E}_{\theta_t}(s(X, Y)|Y = y)$ és $\mathbb{E}_{\theta_t}(s(X, Y))$ majdnem egyenlő (mert a tagokból alkotott sorozatoknak ugyanaz a határértéke).

A kapott szélsőérték nem feltétlenül globális maximum, ennek érdekében különböző θ_0 kezdőértékekből kell indítanunk az algoritmust. A legjobb becslést globális maximumnak feltételezzük.

2.2. Bayes-filter

Az EM-algoritmusban szereplő rejtett Markov-modellben nem ismerjük a

$$p_\theta(X, Y|Y = y)$$

értékeket, emiatt szeretnénk azokat közelíteni. Egy lehetséges közelítés megadására szolgál a Bayes-filter:

Tegyük fel, hogy a rejtett Markov-modellt leíró egyenletrendszer

$$X_k = f(X_{k-1}, u_k, w_k)$$

$$Y_k = g(X_k, n_k)$$

alakú, ahol $u_k \in \mathbb{R}^N$ control input, w_k és n_k zajok. Célunk becslést adni a

$$bel(X_k) = p(X_k|u_{1:k}, Y_{1:k})$$

utólagos valószínűségekre, ehhez megadunk egy rekurziót. Nyilván $bel(X_0) = p(X_0)$.

2.2.1. Lemma.

$$p(x|y, z) = \frac{p(y|x, z) \cdot p(x|z)}{p(y|z)}$$

Bizonyítás.

$$\frac{p(y|x, z) \cdot p(x|z)}{p(y|z)} = \frac{p(y|x, z) \cdot p(x, z)}{p(z) \cdot p(y|z)} = \frac{p(y|z, x) \cdot p(z, x)}{p(y, z)} = \frac{p(x, y, z)}{p(y, z)} = p(x|y, z)$$

□

2.2.2. Állítás. $\exists \eta$ konstans, amire

$$bel(X_k) = \eta \cdot p(Y_k|X_k) \int p(X_k|X_{k-1}, u_k) \cdot bel(X_{k-1}) dX_{k-1}$$

Bizonyítás. Előbbi lemma és a Markov-tulajdonság miatt:

$$\begin{aligned} bel(X_k) &= p(X_k|u_{1:k}, Y_{1:k}) \\ &= p(Y_k|X_k, u_{1:k}, Y_{1:k-1}) \cdot \frac{p(X_k|u_{1:k}, Y_{1:k-1})}{p(Y_k|u_{1:k}, Y_{1:k-1})} \\ &= \eta \cdot p(Y_k|X_k, u_{1:k}, Y_{1:k-1}) \cdot p(X_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta \cdot p(Y_k|X_k) \cdot p(X_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta \cdot p(Y_k|X_k) \cdot \int p(X_k, X_{k-1}|u_{1:k}, Y_{1:k-1}) dX_{k-1} \\ &= \eta \cdot p(Y_k|X_k) \cdot \int p(X_k|X_{k-1}, u_{1:k}, Y_{1:k-1}) \cdot p(X_{k-1}|u_{1:k}, Y_{1:k-1}) dX_{k-1} \\ &= \eta \cdot p(Y_k|X_k) \cdot \int p(X_k|X_{k-1}, u_k) \cdot p(X_{k-1}|u_{1:k-1}, Y_{1:k-1}) dX_{k-1} \\ &= \eta \cdot p(Y_k|X_k) \int p(X_k|X_{k-1}, u_k) \cdot bel(X_{k-1}) dX_{k-1} \end{aligned}$$

□

2.2.3. Megjegyzés. Itt $bel(X_k)$ az X_k állapot utólagos valószínűségét jelöli a k . időpontban, az összes eddigi megfigyelés ($Y_{1:k}$) és beavatkozás ($u_{1:k}$) ismeretében.

2.2.4. Megjegyzés. Alkalmazás: Market making és valódi ár becslése.

A Bayes-filter általános keretet ad a valódi eszközár becsléséhez zajos piaci adatokból. Egy market maker feladata, hogy vételi (bid) és eladási (ask) árakat határozzon meg. A valódi ár v_t nem megfigyelhető közvetlenül, de a kereskedések árából következtethetünk rá.

Modell:

$$\begin{aligned} v_t &= v_{t-1} + \eta_t, & \eta_t &\sim \mathcal{N}(0, \sigma_v^2) \\ p_t &= v_t + \varepsilon_t, & \varepsilon_t &\sim \mathcal{N}(0, \sigma_p^2) \end{aligned}$$

A Bayes-filter (jelen esetben a Kalman-szűrő) becslést ad a valódi árra ($\hat{v}_t$) és annak bizonytalanságára (σ_t). A market maker stratégiája:

$$\begin{aligned} bid_t &= \hat{v}_t - \delta - \gamma \cdot \sigma_t \\ ask_t &= \hat{v}_t + \delta + \gamma \cdot \sigma_t \end{aligned}$$

ahol δ a tranzakciós költségek fedezete, γ pedig a kockázati prémium. Minél nagyobb a bizonytalanság (σ_t), annál szélesebb a bid-ask spread.

2.3. Bayes-filter konvergenciája

Ebben az alfejezetben a Bayes-szűrő konvergenciáját vizsgáljuk. Megmutatjuk hogy a szűrő által szolgáltatott utólagos eloszlás exponenciális sebességgel felejt el a kezdeti feltételeket ha a rendszer egy ún. gyenge keveredési feltételt teljesít. A bizonyítás a szűrő operátorának projektív metrikabeli kontrakciós tulajdonságán alapul.

Alapfogalmak és jelölések

Legyen $(X_n)_{n \geq 0}$ egy $\mathcal{X}$ állapotterű Markov-lánc, $(Y_n)_{n \geq 1}$ a megfigyelések sorozata. Feltételezzük, hogy a modell a következő alakú:

- $X_0 \sim \mu_0$ kezdeti eloszlás,
- $(X_n \mid X_{n-1} = x) \sim Q(\cdot \mid x)$ átmenetmag,
- $(Y_n \mid X_n = x) \sim P(\cdot \mid x)$ kibocsátási mag.

A szűrő célja a π_n -nel jelölt utólagos eloszlás számítása:

$$\pi_n(f) := \mathbb{E}[f(X_n) \mid Y_1, \dots, Y_n]$$

Jelölje $\mathcal{P}(\mathcal{X})$ a $\mathcal{X}$ feletti valószínűségi mértékek terét. A szűrő rekurziója két lépésből áll.

Predikció (control update):

$$\pi_{n|n-1}(f) = \int_{\mathcal{X}} f(x) \pi_{n-1}(Q(\cdot \mid x)) dx$$

Korrekción (measurement update):

$$\pi_n(f) = \frac{\pi_{n|n-1}(f \cdot p(Y_n \mid \cdot))}{\pi_{n|n-1}(p(Y_n \mid \cdot))}$$

ahol $p(y \mid x)$ a kibocsátási sűrűségfüggvény.

A konvergenciatétel

2.3.1. Tétel (Bayes-szűrő konvergenciája). *Tegyük fel, hogy a következő gyenge keveredési feltétel teljesül:*

Létezik olyan $\alpha \in (0, 1)$ és $C < \infty$, hogy a Q átmenetmagra $\forall x, x' \in \mathcal{X}$ és n -re

$$\rho(Q(\cdot | x), Q(\cdot | x')) \leq C \cdot \alpha^n,$$

ahol ρ a Hilbert-féle projektív metrika.

Ekkor a Bayes-szűrő operátora kontrakció a projektív metrikában, azaz bármely két, különböző kezdeti eloszlásból (π_0 és π'_0) indított szűrő kimenetére:

$$\rho(\pi_n, \pi'_n) \leq C \cdot \alpha^n \cdot \rho(\pi_0, \pi'_0)$$

Következésképpen a teljes variációs normában:

$$\|\pi_n - \pi'_n\|_{TV} \longrightarrow 0 \quad (n \rightarrow \infty)$$

és a konvergencia sebessége exponenciális:

$$\|\pi_n - \pi'_n\|_{TV} = O(\alpha^n)$$

A bizonyítás eszközei

A projektív metrika

2.3.2. Definíció (Projektív metrika). Legyen μ egy tetszőleges σ -véges mérték, és legyenek $p, q \in L^1(\mu)$ szigorúan pozitív sűrűségfüggvények. A **Hilbert-féle projektív metrika** a következőképpen definiálható:

$$\rho(p, q) := \log \left(\sup_A \frac{p(A)/\mu(A)}{q(A)/\mu(A)} \cdot \sup_A \frac{q(A)/\mu(A)}{p(A)/\mu(A)} \right)$$

vagy ekvivalens módon:

$$\rho(p, q) = \sup_{x, y} \left| \log \frac{p(x)}{q(x)} - \log \frac{p(y)}{q(y)} \right|$$

2.3.3. Megjegyzés. A projektív metrika invariáns a konstans szorzóra nézve: $\rho(\lambda p, \mu q) = \rho(p, q)$ minden $\lambda, \mu > 0$ -ra. Továbbá a teljes variációs normával való kapcsolata:

$$\|p - q\|_{TV} \leq \frac{2}{\sqrt{e^{\rho(p, q)} + 1}} \cdot \rho(p, q)$$

amiből következik, hogy a projektív metrikabeli konvergencia maga után vonja a teljes variációs konvergenciát.

2.3.4. Lemma (Korrektíós operátor kontrakciója). *Legyen $p, q \in \mathcal{P}(\mathcal{X})$ két sűrűségfüggvény, és legyen y egy rögzített megfigyelés. Defináljuk a korrektíós operátort:*

$$(T_y p)(x) := \frac{p(x) \cdot p(y | x)}{\int_{\mathcal{X}} p(z) \cdot p(y | z) dz}$$

Ekkor a projektív metrikában a korrektíós operátor nem növeli a távolságot, azaz

$$\rho(T_y p, T_y q) \leq \rho(p, q)$$

Bizonyítás. A projektív metrika definíciójából:

$$\rho(T_y p, T_y q) = \rho(p \cdot p(y | \cdot), q \cdot p(y | \cdot))$$

Mivel a szorzás egy pozitív függvénnyel a projektív metrikában mindig kontrakció (azaz $\rho(f \cdot p, f \cdot q) \leq \rho(p, q)$), ezért:

$$\rho(T_y p, T_y q) \leq \rho(p, q)$$

Ez a lépés tehát nem okoz információvesztést a kezdeti feltételek feledésében. $\square$

2.3.5. Lemma (Predikciós operátor kontrakciója). *Legyen Q az átmenetmag. A predikciós operátor:*

$$(Pp)(x) := \int_{\mathcal{X}} Q(x | z) p(z) dz$$

Ekkor a gyenge keveredési feltétel teljesülése esetén:

$$\rho(Pp, Pq) \leq C \cdot \alpha^n \cdot \rho(p, q)$$

Bizonyítás. A bizonyítás a keveredési feltétel direkt alkalmazása. A feltétel szerint:

$$\rho(Q(\cdot | x), Q(\cdot | x')) \leq C \cdot \alpha^n$$

Mivel Pp és Pq a Q keverékei p és q szerint, a projektív metrika konvexitásából:

$$\rho(Pp, Pq) \leq \sup_{x, x'} \rho(Q(\cdot | x), Q(\cdot | x')) \leq C \cdot \alpha^n \cdot \rho(p, q)$$

A $\rho(Pp, Pq)$ és $\rho(p, q)$ közötti kapcsolatot a keveredési feltétel biztosítja. $\square$

A tétel bizonyítása

Bizonyítás. Legyen π_n és π'_n két szűrő kimenete, amelyeket két különböző kezdeti eloszlásból (π_0 és π'_0) indítottunk.

A szűrő rekurziója a predikció és a korrekció kompozíciója:

$$\pi_n = T_{Y_n} \circ P \circ T_{Y_{n-1}} \circ P \circ \dots \circ T_{Y_1} \circ P(\pi_0)$$

A fenti lemmák alapján minden egyes lépés kontrakció:

1. A predikciós operátor P kontrakció: $\rho(Pp, Pq) \leq C \cdot \alpha^n \cdot \rho(p, q)$
2. A korrekciós operátor T_y nem növeli a távolságot: $\rho(T_y p, T_y q) \leq \rho(p, q)$

Ezeket rekurzívan alkalmazva:

$$\rho(\pi_n, \pi'_n) \leq \rho(P\pi_{n-1}, P\pi'_{n-1}) \leq C \cdot \alpha^n \cdot \rho(\pi_0, \pi'_0)$$

A jobb oldal $n \rightarrow \infty$ esetén 0-hoz tart, mivel $\alpha \in (0, 1)$.

Mivel a projektív metrika és a teljes variációs norma között fennáll az alábbi kapcsolat:

$$\|p - q\|_{TV} \leq \frac{2}{\sqrt{e^{\rho(p, q)} + 1}} \cdot \rho(p, q)$$

ezért a projektív metrikabeli konvergencia maga után vonja a teljes variációs konvergenciát:

$$\|\pi_n - \pi'_n\|_{TV} \longrightarrow 0 \quad (n \rightarrow \infty)$$

A konvergencia sebessége a jobb oldal $C \cdot \alpha^n$ alakjából adódóan exponenciális:

$$\|\pi_n - \pi'_n\|_{TV} = O(\alpha^n)$$

Ezzel a tételt bebizonyítottuk. $\square$

2.3.6. Megjegyzés. A keveredési feltétel biztosítja hogy a Markov-lánc elfelejti a kezdeti állapotot. Ez a feltétel a legtöbb gyakorlati alkalmazásban (pl. stacionárius, ergodikus folyamatok) teljesül.

2.3.7. Megjegyzés. Ha a megfigyelések korlátlanul informatívak a korrekció beragaszthatja a szűrőt egy adott állapotba így a konvergencia csak a predikción keresztül valósulhat meg.

3. fejezet

Diszkrét állapotterű rejtett Markov-modell

3.1. Forward-Backward algoritmus

A diszkrét idejű rejtett Markov-modellek egyik legalapvetőbb algoritmus a Forward-Backward algoritmus ami lehetővé teszi hogy egy megfigyeléssorozat ismeretében kiszámítsuk a rejtett állapotokra vonatkozó utólagos valószínűségeket, valamint az EM-algoritmus E-lépéséhez szükséges mennyiségeket.

Legyen adott egy $(X_n, Y_n)_{n=1}^T$ diszkrét idejű rejtett Markov-modell, ahol $X_n \in \{1, 2, \dots, N\}$ a rejtett állapotok, $Y_n \in \{1, 2, \dots, M\}$ a megfigyelések. A modell paraméterei:

- $\pi_i = P(X_1 = i)$ a kezdeti eloszlás,
- $A_{ij} = P(X_{n+1} = j | X_n = i)$ az átmenetvalószínűségek mátrixa,
- $B_{ik} = P(Y_n = k | X_n = i)$ a kibocsátási valószínűségek mátrixa.

A modell paraméterei tehát $\theta = (\pi, A, B)$. Célunk hogy a megfigyelések $y_{1:T} = (y_1, \dots, y_T)$ ismeretében kiszámítsuk a következő mennyiségeket:

1. A szűrt valószínűségeket: $\alpha_n(i) = P(X_n = i, y_{1:n})$
2. A simított valószínűségeket: $\beta_n(i) = P(y_{n+1:T} | X_n = i)$
3. Az utólagos állapotvalószínűségeket: $bel_n(i) = P(X_n = i | y_{1:T})$
4. Az átmenet-utólagosokat: $\xi_n(i, j) = P(X_n = i, X_{n+1} = j | y_{1:T})$

Itt $bel_n(i)$ jelöli az i . állapot utólagos valószínűségét a n . időpontban, a teljes megfigyeléssorozat ismeretében.

Forward algoritmus

A Forward algoritmus rekurzívan számítja ki az $\alpha_n(i)$ mennyiségeket. Az inicializáció a teljes valószínűség tétele alapján:

$$\alpha_1(i) = P(X_1 = i, Y_1 = y_1) = P(Y_1 = y_1 | X_1 = i) \cdot P(X_1 = i) = B_{iy_1} \pi_i.$$

A rekurzióhoz alkalmazzuk a Markov-tulajdonságot:

$$\begin{aligned}
\alpha_{n+1}(j) &= P(X_{n+1} = j, y_{1:n+1}) \\
&= P(y_{n+1}|X_{n+1} = j, y_{1:n}) \cdot P(X_{n+1} = j, y_{1:n}) \\
&= B_{jy_{n+1}} \sum_{i=1}^N P(X_{n+1} = j|X_n = i) \cdot P(X_n = i, y_{1:n}) \\
&= B_{jy_{n+1}} \sum_{i=1}^N A_{ij} \alpha_n(i).
\end{aligned}$$

Tehát a Forward algoritmus:

$$\begin{aligned}
\alpha_1(i) &= \pi_i \cdot B_{iy_1} \quad (\text{inicializáció}) \\
\alpha_{n+1}(j) &= B_{jy_{n+1}} \sum_{i=1}^N \alpha_n(i) A_{ij} \quad (\text{rekurzió})
\end{aligned}$$

A megfigyelések teljes valószínűsége az α változókból számítható:

$$P(y_{1:T}) = \sum_{i=1}^N \alpha_T(i)$$

Backward algoritmus

A Backward algoritmus rekurzívan számítja ki a $\beta_n(i)$ mennyiségeket. Az inicializáció triviális: $P(\emptyset|X_T = i) = 1$, tehát $\beta_T(i) = 1$. A rekurzióhoz:

$$\begin{aligned}
\beta_n(i) &= P(y_{n+1:T}|X_n = i) \\
&= \sum_{j=1}^N P(X_{n+1} = j, y_{n+1:T}|X_n = i) \\
&= \sum_{j=1}^N P(X_{n+1} = j|X_n = i) \cdot P(y_{n+1:T}|X_{n+1} = j) \\
&= \sum_{j=1}^N A_{ij} \cdot P(y_{n+1}|X_{n+1} = j) \cdot P(y_{n+2:T}|X_{n+1} = j) \\
&= \sum_{j=1}^N A_{ij} B_{jy_{n+1}} \beta_{n+1}(j).
\end{aligned}$$

Tehát a Backward algoritmus:

$$\begin{aligned}
\beta_T(i) &= 1 \quad (\text{inicializáció}) \\
\beta_n(i) &= \sum_{j=1}^N A_{ij} B_{jy_{n+1}} \beta_{n+1}(j) \quad (\text{rekurzió})
\end{aligned}$$

Utólagos állapot- és átmenetvalószínűségek

Az α és β változók segítségével kiszámíthatjuk a $bel_n(i)$ utólagos állapotvalószínűségeket. A Bayes-tétel és a feltételes függetlenség miatt:

$$\begin{aligned}
P(X_n = i|y_{1:T}) &= \frac{P(X_n = i, y_{1:T})}{P(y_{1:T})} \\
&= \frac{P(X_n = i, y_{1:n}) \cdot P(y_{n+1:T}|X_n = i)}{P(y_{1:T})} \\
&= \frac{\alpha_n(i) \beta_n(i)}{P(y_{1:T})}.
\end{aligned}$$

Tehát:

$$bel_n(i) = P(X_n = i | y_{1:T}) = \frac{\alpha_n(i)\beta_n(i)}{\sum_{j=1}^N \alpha_T(j)}$$

Az átmenet-utólagosokhoz a Bayes-tétel és a Markov-tulajdonság alkalmazásával:

$$\begin{aligned} P(X_n = i, X_{n+1} = j, y_{1:T}) &= P(X_n = i, y_{1:n}) \cdot P(X_{n+1} = j | X_n = i) \\ &\quad \cdot P(y_{n+1} | X_{n+1} = j) \cdot P(y_{n+2:T} | X_{n+1} = j) \\ &= \alpha_n(i) \cdot A_{ij} \cdot B_{jy_{n+1}} \cdot \beta_{n+1}(j). \end{aligned}$$

Osztva $P(y_{1:T})$ -vel:

$$\xi_n(i, j) = P(X_n = i, X_{n+1} = j | y_{1:T}) = \frac{\alpha_n(i)A_{ij}B_{jy_{n+1}}\beta_{n+1}(j)}{\sum_{k=1}^N \alpha_T(k)}$$

Skálázott Forward-Backward algoritmus

Legyen $\alpha_n(i) = P(X_n = i, y_{1:n})$ és $\beta_n(i) = P(y_{n+1:T} | X_n = i)$. A skálázott változók:

$$\hat{\alpha}_n(i) = \frac{\alpha_n(i)}{\sum_{j=1}^N \alpha_n(j)}, \quad \hat{\beta}_n(i) = \frac{\beta_n(i)}{\sum_{j=1}^N \beta_n(j)}$$

A skálázási faktorok:

$$c_n = \sum_{j=1}^N \alpha_n(j)$$

Ekkor a log-likelihood:

$$\log P(y_{1:T}) = \sum_{n=1}^T \log c_n$$

Forward-Backward algoritmus konvergenciája

3.1.1. Tétel (Forward-Backward konvergencia). *Tegyük fel, hogy a Markov-lánc irreducibilis és aperiodikus, továbbá a kibocsátási sűrűségek pozitívak. Ekkor a skálázott Forward-Backward algoritmus által kiszámolt utólagos valószínűségek:*

$$\pi_n(i) = \hat{\alpha}_n(i)\hat{\beta}_n(i)$$

konvergálnak a valódi utólagos valószínűségekhez, azaz:

$$\pi_n(i) \longrightarrow P(X_n = i | y_{1:T}) \quad (T \rightarrow \infty)$$

A konvergencia sebessége exponenciális:

$$|\pi_n(i) - P(X_n = i | y_{1:T})| = O(\alpha^n)$$

valamely $\alpha \in (0, 1)$ -re.

Bizonyítás. 1. A szűrő konvergenciája: A Bayes-szűrő operátora kontrakció a teljes variációs normában, ha a keveredési feltétel teljesül. Ez azt jelenti, hogy a predikciós eloszlás konvergál a stacionárius eloszláshoz:

$$\|\pi_{n|n-1} - \pi^*\|_{TV} \leq C \cdot \alpha^n$$

2. A simítás konvergenciája: A $\beta_n(i)$ változók a jövőbeli megfigyelések valószínűségét adják. A keveredési feltétel miatt:

$$|\beta_n(i) - \beta_n(j)| \leq C \cdot \alpha^{T-n}$$

3. Az utólagos valószínűségek konvergenciája: A Bayes-tételből:

$$\pi_n(i) = \frac{\alpha_n(i)\beta_n(i)}{\sum_j \alpha_n(j)\beta_n(j)}$$

A fenti becsléseket behelyettesítve:

$$|\pi_n(i) - P(X_n = i \mid y_{1:T})| \leq C \cdot \alpha^{\min(n, T-n)}$$

Mivel $\alpha \in (0, 1)$, a jobb oldal $T \rightarrow \infty$ esetén 0-hoz tart. $\square$

3.2. Baum-Welch algoritmus

A Baum-Welch algoritmus az EM-algoritmus speciális esete rejtett Markov-modellek paraméterbecslésére. Az újrabecslési formulák intuitív jelentése:

- $\pi_i^{\text{new}} = \text{bel}_1(i)$: az i . állapot várható kezdeti valószínűsége,
- $A_{ij}^{\text{new}} = \frac{\sum_{n=1}^{T-1} \xi_n(i, j)}{\sum_{n=1}^{T-1} \text{bel}_n(i)}$: az i -ből j -be történő átmenetek várható száma osztva az i -ből történő kilépések várható számával,
- $B_{ik}^{\text{new}} = \frac{\sum_{n=1}^T \text{bel}_n(i) \cdot I(y_n = k)}{\sum_{n=1}^T \text{bel}_n(i)}$: a k . megfigyelés várható száma az i . állapotban osztva az i . állapotban töltött várható idővel.

Formálisan:

$$\begin{aligned} \pi_i^{\text{new}} &= \text{bel}_1(i) \\ A_{ij}^{\text{new}} &= \frac{\sum_{n=1}^{T-1} \xi_n(i, j)}{\sum_{n=1}^{T-1} \text{bel}_n(i)} \\ B_{ik}^{\text{new}} &= \frac{\sum_{n=1}^T \text{bel}_n(i) \cdot I(y_n = k)}{\sum_{n=1}^T \text{bel}_n(i)} \end{aligned}$$

A Baum-Welch algoritmus monoton növeli a megfigyelések log-likelihoodját:

$$P(y_{1:T} \mid \theta^{\text{new}}) \geq P(y_{1:T} \mid \theta)$$

és konvergál egy lokális maximumhoz. A bizonyítás az EM-algoritmus általános konvergenciatételén alapul.

A likelihood monoton növekedése

3.2.1. Tétel (Baum-Welch konvergencia). *Legyen Λ a régi, Λ' az új modell. A Baum-Welch algoritmus minden iterációban növeli (vagy legalább nem csökkenti) a megfigyelések log-likelihoodját:*

$$\log P(y_{1:T} \mid \Lambda') \geq \log P(y_{1:T} \mid \Lambda)$$

Egyenlőség akkor és csak akkor áll fenn, ha $\Lambda = \Lambda'$.

Bizonyítás. A bizonyítás a Kullback-Leibler divergencia nem-negativitásán alapul.

1. A likelihood hányados felírása: A log-likelihood hányadost kibővítjük a $P(X_{1:T} \mid y_{1:T}, \Lambda')$ mennyiséggel:

$$\log \frac{P(y_{1:T} \mid \Lambda)}{P(y_{1:T} \mid \Lambda')} = \sum_{X_{1:T}} P(X_{1:T} \mid y_{1:T}, \Lambda') \log \frac{P(y_{1:T}, X_{1:T} \mid \Lambda)}{P(y_{1:T}, X_{1:T} \mid \Lambda')} \cdot \frac{P(X_{1:T} \mid y_{1:T}, \Lambda')}{P(X_{1:T} \mid y_{1:T}, \Lambda)}$$

2. Szétválasztás két tagra: A fenti kifejezés két tagra bontható:

- $L(\Lambda, \Lambda') = \sum_{X_{1:T}} P(X_{1:T} | y_{1:T}, \Lambda') \log \frac{P(y_{1:T}, X_{1:T} | \Lambda)}{P(y_{1:T}, X_{1:T} | \Lambda')}$
- $KL(P(X_{1:T} | y_{1:T}, \Lambda') || P(X_{1:T} | y_{1:T}, \Lambda)) \geq 0$

3. A Baum-Welch algoritmus maximalizálja L -et: A Baum-Welch algoritmus M-lépése pontosan $L(\Lambda, \Lambda')$ -t maximalizálja Λ' -re nézve. Ezért:

$$L(\Lambda', \Lambda') \geq L(\Lambda, \Lambda')$$

4. Következtetés:

$$\log \frac{P(y_{1:T} | \Lambda)}{P(y_{1:T} | \Lambda')} = L(\Lambda, \Lambda') + KL(\cdot) \geq 0$$

Ebből:

$$\log P(y_{1:T} | \Lambda') \geq \log P(y_{1:T} | \Lambda)$$

A likelihood tehát minden iterációban nő vagy stagnál mígnem eléri a konvergenciát. $\square$

Gyakorlati implementáció és numerikus stabilitás

A Forward-Backward algoritmus teljes implementációja az alábbi lépésekből áll:

1. **Forward lépés:** Számítsuk ki $\alpha_1(i)$ -t minden i -re, majd rekurzívan $\alpha_n(i)$ -t $n = 2, \dots, T$ -ig.
2. **Backward lépés:** Számítsuk ki $\beta_T(i)$ -t minden i -re, majd rekurzívan $\beta_n(i)$ -t $n = T - 1, \dots, 1$ -ig.
3. **Utólagosok számítása:** Számítsuk ki $bel_n(i)$ -t és $\xi_n(i, j)$ -t minden n, i, j -re.
4. **Újrabecslés:** Frissítsük a paramétereket a Baum-Welch formulákkal.

Az algoritmus számítási komplexitása $O(T \cdot N^2)$, ahol T az időlépések száma és N az állapotok száma.

3.2.2. *Megjegyzés. Alkalmazás: Piaci rezsimek azonosítása.* Tegyük fel, hogy egy részvényindex (pl. S&P 500) napi hozamait két rejtett állapottal modellezzük:

- $X_t = 1$: nyugodt piac (alacsony volatilitás, pozitív várható hozam)
- $X_t = 2$: volatilis piac (magas volatilitás, negatív vagy nulla várható hozam)

A megfigyelések Y_t a napi hozamok, amelyeket feltételes normális eloszlással modellezünk:

$$Y_t | X_t = i \sim \mathcal{N}(\mu_i, \sigma_i^2), \quad i = 1, 2$$

A Baum-Welch algoritmus segítségével becsülhetjük a modell paramétereit $(\pi, A, \mu_1, \sigma_1, \mu_2, \sigma_2)$ a historikus adatokból. A Forward-Backward algoritmus minden időpontra kiszámítja a $bel_t(i) = P(X_t = i | y_{1:T})$ utólagos valószínűségeket, azaz annak valószínűségét, hogy az adott napon melyik rezsime volt jelen.

4. fejezet

Folytonos állapotterű rejtett Markov-modell

4.1. Kalman-szűrő

A Bayes-filter algoritmus a gyakorlatban csak speciális esetekben számolható zárt alakban. A két fő korlátozó tényező:

- Az integrál elvégzése a predikciós lépésben,
- Az utólagos sűrűségfüggvény reprezentációja.

A Kalman-szűrő a Bayes-filter zárt alakú megoldása lineáris Gauss-rendszerekre. Ez az egyik leggyakrabban használt szűrő a gyakorlatban, köszönhetően egyszerűségének és optimális tulajdonságainak.

Lineáris Gauss-rendszerek: A Kalman-szűrő a következő három feltevessel él:

1. Az állapotátmenet lineáris, additív Gauss-zajjal:

$$x_t = A_t x_{t-1} + B_t u_t + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, R_t)$$

2. A megfigyelési modell lineáris, additív Gauss-zajjal:

$$z_t = C_t x_t + \delta_t, \quad \delta_t \sim \mathcal{N}(0, Q_t)$$

3. A kezdeti állapot Gauss-eloszlású:

$$bel(x_0) = \mathcal{N}(x_0; \mu_0, \Sigma_0)$$

Ezek a feltételek biztosítják, hogy az utólagos eloszlás minden időpontban Gauss-eloszlású maradjon.

Kalman-szűrő algoritmus:

A szűrő a $bel(x_t)$ eloszlást a μ_t várható értékkel és a Σ_t kovarianciamátrixszal reprezentálja.

Predikciós lépés:

$$\begin{aligned}\bar{\mu}_t &= A_t \mu_{t-1} + B_t u_t \\ \bar{\Sigma}_t &= A_t \Sigma_{t-1} A_t^T + R_t\end{aligned}$$

Korrektciós lépés:

$$\begin{aligned}K_t &= \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1} \\ \mu_t &= \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t) \\ \Sigma_t &= (I - K_t C_t) \bar{\Sigma}_t\end{aligned}$$

ahol K_t a Kalman-erősítés (Kalman gain).

Kalman-szűrő levezetése:

A predikciós lépés a Bayes-filter predikciós képletéből származik. Mivel mindkét tényező Gauss-eloszlású, a konvolúciójuk is Gauss-eloszlású:

$$\overline{bel}(x_t) = \int \mathcal{N}(x_t; A_t x_{t-1} + B_t u_t, R_t) \cdot \mathcal{N}(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}) dx_{t-1}$$

A szorzat Gauss-eloszlású, paraméterei a fenti predikciós képletek.

A korrekciós lépés a Bayes-tétel alkalmazása:

$$bel(x_t) = \eta \cdot p(z_t | x_t) \cdot \overline{bel}(x_t) = \eta \cdot \mathcal{N}(z_t; C_t x_t, Q_t) \cdot \mathcal{N}(x_t; \bar{\mu}_t, \bar{\Sigma}_t)$$

Két Gauss-eloszlás szorzata is Gauss-eloszlású, paraméterei a fenti korrekciós képletek.

Tulajdonságok

- **Optimalitás:** A Kalman-szűrő minimális négyzetes hiba értelemben optimális becslést ad lineáris Gauss-rendszerekben.
- **Rekurzivitás:** A szűrő csak az előző állapotbecslést és az aktuális megfigyelést használja, így online alkalmazható.
- **Komplexitás:** Minden lépés $O(n^3)$ időigényű a mátrixinverzió miatt, ahol n az állapottér dimenziója.

4.1.1. *Megjegyzés.* **Kalman-szűrő alkalmazásai:**

Trendkövetés: Legyen p_t egy eszköz árfolyama. Feltételezzük, hogy az árfolyam egy rejtett trend körül ingadozik:

$$\begin{aligned} \mu_t &= \mu_{t-1} + \eta_t, & \eta_t &\sim \mathcal{N}(0, \sigma_\eta^2) \\ p_t &= \mu_t + \varepsilon_t, & \varepsilon_t &\sim \mathcal{N}(0, \sigma_\varepsilon^2) \end{aligned}$$

Ez a modell Kalman-szűrő formában: $x_t = \mu_t$, $A_t = 1$, $R_t = \sigma_\eta^2$, $C_t = 1$, $Q_t = \sigma_\varepsilon^2$. A szűrő minden időpontban becslést ad a trendre (μ_t) és annak bizonytalanságára (σ_t^2).

Volatilitás becslése: A sztochasztikus volatilitás modellekben a log-volatilitás rejtett állapot:

$$\begin{aligned} r_t &= \sigma_t \varepsilon_t, & \varepsilon_t &\sim \mathcal{N}(0, 1) \\ \log \sigma_t^2 &= \log \sigma_{t-1}^2 + \eta_t, & \eta_t &\sim \mathcal{N}(0, \sigma_\eta^2) \end{aligned}$$

Ez a modell nemlineáris, ezért EKF vagy UKF szükséges a becsléshez. A becült volatilitás opciók árazására és kockázatkezelésre használható.

Faktor timing: Dinamikus faktor modellekben a faktor-súlyok időben változnak:

$$R_t = \alpha_t + \sum_{k=1}^K \beta_t^k F_t^k + \varepsilon_t, \quad \theta_t = \theta_{t-1} + \eta_t$$

ahol $\theta_t = (\alpha_t, \beta_t^1, \dots, \beta_t^K)^T$. A Kalman-szűrő dinamikus becslést ad a faktor-súlyokra, ami lehetővé teszi a faktorstratégiák időzítését.

4.2. Kiterjesztett Kalman-szűrő (EKF)

A valós problémákban az állapotátmenet és a megfigyelési modell gyakran nemlineáris. A kiterjesztett Kalman-szűrő (EKF) a Kalman-szűrő általánosítása nemlineáris rendszerekre.

A nemlineáris modell:

$$\begin{aligned}x_t &= g(u_t, x_{t-1}) + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, R_t) \\z_t &= h(x_t) + \delta_t, \quad \delta_t \sim \mathcal{N}(0, Q_t)\end{aligned}$$

ahol g és h nemlineáris függvények.

Linearizáció: Az EKF a nemlineáris függvényeket Taylor-sorral linearizálja az aktuális becslés körül:

$$\begin{aligned}g(u_t, x_{t-1}) &\approx g(u_t, \mu_{t-1}) + G_t(x_{t-1} - \mu_{t-1}) \\h(x_t) &\approx h(\bar{\mu}_t) + H_t(x_t - \bar{\mu}_t)\end{aligned}$$

ahol G_t és H_t a Jacobi-mátrixok:

$$G_t = \left. \frac{\partial g}{\partial x_{t-1}} \right|_{u_t, \mu_{t-1}}, \quad H_t = \left. \frac{\partial h}{\partial x_t} \right|_{\bar{\mu}_t}$$

Az EKF algoritmusa:

Predikció:

$$\begin{aligned}\bar{\mu}_t &= g(u_t, \mu_{t-1}) \\\bar{\Sigma}_t &= G_t \Sigma_{t-1} G_t^T + R_t\end{aligned}$$

Korrekción:

$$\begin{aligned}K_t &= \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1} \\\mu_t &= \bar{\mu}_t + K_t(z_t - h(\bar{\mu}_t)) \\\Sigma_t &= (I - K_t H_t) \bar{\Sigma}_t\end{aligned}$$

Az EKF korlátai:

- A linearizáció csak lokálisan pontos; nagy bizonytalanság esetén hibás lehet.
- A Jacobi-mátrixok számítása analitikusan nehéz vagy numerikusan instabil lehet.
- Az utólagos eloszlás csak közelítőleg Gauss-eloszlású.

4.3. σ -pontos Kalman-szűrő (UKF)

A σ -pontos Kalman-szűrő (UKF) alternatív megközelítést kínál a nemlineáris rendszerek szűrésére. Ahelyett, hogy a nemlineáris függvényeket linearizálná, az UKF determinisztikus sigma-pontokat használ a Gauss-eloszlás reprezentálására.

Az σ -pontos transzformáció:

Egy n -dimenziós Gauss-eloszláshoz $2n + 1$ sigma-pontot választunk:

$$\begin{aligned}\mathcal{X}^{[0]} &= \mu \\\mathcal{X}^{[i]} &= \mu + \left(\sqrt{(n + \lambda) \Sigma} \right)_i, \quad i = 1, \dots, n \\\mathcal{X}^{[i]} &= \mu - \left(\sqrt{(n + \lambda) \Sigma} \right)_{i-n}, \quad i = n + 1, \dots, 2n\end{aligned}$$

A sigma-pontok súlyai:

$$\begin{aligned}w_m^{[0]} &= \frac{\lambda}{n + \lambda} \\w_c^{[0]} &= \frac{\lambda}{n + \lambda} + (1 - \alpha^2 + \beta) \\w_m^{[i]} &= w_c^{[i]} = \frac{1}{2(n + \lambda)}, \quad i = 1, \dots, 2n\end{aligned}$$

A sigma-pontokat átvezetjük a nemlineáris függvényen:

$$\mathcal{Y}^{[i]} = g(\mathcal{X}^{[i]})$$

majd visszanyerjük a Gauss-eloszlás paramétereit:

$$\mu' = \sum_{i=0}^{2n} w_m^{[i]} \mathcal{Y}^{[i]}$$
$$\Sigma' = \sum_{i=0}^{2n} w_c^{[i]} (\mathcal{Y}^{[i]} - \mu') (\mathcal{Y}^{[i]} - \mu')^T$$

Az UKF előnyei az EKF-fel szemben:

- Nem szükséges Jacobi-mátrixok számítása (derivált-mentes szűrő).
- Pontosabb közelítést ad erősen nemlineáris rendszerekben.
- A sigma-pontos megközelítés a Taylor-sor magasabb rendű tagjait is figyelembe veszi.

Az UKF algoritmus:

A szűrő minden lépésben:

1. Sigma-pontok generálása az aktuális becslésből.
2. A sigma-pontok átvezetése a nemlineáris állapotátmeneten.
3. A predikció kiszámítása a transzformált pontokból.
4. Új sigma-pontok generálása a predikcióból.
5. A sigma-pontok átvezetése a nemlineáris megfigyelési modellen.
6. A korrekció kiszámítása a transzformált pontokból.