
Madár Patrik

Markov-láncok

Folyamatosan frissülő jegyzet

Budapest, 2026

Tartalomjegyzék

1. Fogalmak	3
1.1. Markov-láncok bevezetése	3
1.2. Rejtett Markov-modell	5
2. Markov-láncok becslése	6
2.1. Expectation-Maximization algoritmus	6
2.2. Bayes-filter	8
3. Diszkrét állapotterű rejtett Markov-modell	9
3.1. Forward-Backward algoritmus	9

1. fejezet

Fogalmak

1.1. Markov-láncok bevezetése

1.1.1. Definíció. Legyen adott elemi események Ω halmazán értelmezett A σ -algebra. Ekkor (Ω, A) -t mérhető térnek, és $\mu : A \rightarrow [0; \infty]$ -t mértéknek nevezzük, ha $\mu(\emptyset) = 0$ és diszjunkt $A_i \in A$ -kra

$$\mu\left(\bigcup A_i\right) = \sum \mu(A_i),$$

végül az (Ω, A, μ) rendezett hármaszt mértéktérnek nevezzük.

1.1.2. Definíció. Azt a legszűkebb σ -algebrát, ami tartalmazza $\mathbb{R}$ nyílt részhalmazait, Borel-mérhető halmazok rendszerének nevezzük, melynek elemei a Borel-mérhető halmazok (ha az alaphalmaz nem $\mathbb{R}$, akkor az adott topologikus tér nyílt halmazait tartalmazó legszűkebb σ -algebra).

1.1.3. Definíció. (Ω, A) mérhető téren értelmezett $f : \Omega \rightarrow \mathbb{R}$ függvény mérhető függvény, ha $\forall \mathbb{R}$ -ben Borel-mérhető halmaz f általi ösképe mérhető, azaz $\in A$. Ha $P : A \rightarrow [0; 1]$ mérték, melyre $P(\Omega) = 1$, akkor az (Ω, A, P) hármaszt valószínűségi mezőnek nevezzük.

1.1.4. Definíció. (Ω, A, P) valószínűségi mező Ω eseményterén értelmezett $X : \Omega \rightarrow \mathbb{R}$ függvény valószínűségi változó (ez a hivatalos definíció), ha $\forall x \in \mathbb{R}$ -re

$$\{\omega \in \Omega : X(\omega) \leq x\} \in A$$

1.1.5. Megjegyzés. Általában valós/vektorértékű valószínűségi változón egy (Ω, A, P) valószínűségi mezőn definiált $(\mathbb{R}^n, \mathbb{B}^n)$ értékű mérhető függvényt értünk, ahol $\mathbb{B}^n$ az $\mathbb{R}^n$ -ben Borel-mérhető halmazok σ -algebrája. Külön kikötés hiányában I halmaz Borel-halmazait $\mathbb{B}_I$ vagy $\mathbb{B}$ jelöli (utóbbi csak akkor, ha a jelölés egyértelmű).

1.1.6. Definíció. Az (Ω, A, P) valószínűségi mezőn értelmezett X valószínűségi változó eloszlásfüggvénye $F_X : \mathbb{R} \rightarrow \mathbb{R}$, $F_X(x) = P(X < x)$. $f : \mathbb{R} \rightarrow \mathbb{R}$ az X abszolút folytonos valószínűségi változó sűrűségfüggvénye, ha $F_X(x) = \int_{-\infty}^x f(t)dt$.

1.1.7. Definíció. Az (Ω, A, P) valószínűségi mezőn és annak T időhalmazán értelmezett

$$X(t, \omega) : T \times \Omega \rightarrow \mathbb{R}$$

kétváltozós függvény **sztochasztikus folyamat**, ha $\forall$ rögzített $t \in T$ -re $X(t, \omega)$ az (Ω, A, P) valószínűségi mezőn értelmezett valószínűségi változó. Az $X(t; \omega)$ a $T = \mathbb{N}$ esetben diszkrét idejű, $T = [0; \infty)$ esetben folytonos idejű sztochasztikus folyamat. Rögzített $\omega_0 \in \Omega$ -ra

$$X(t, \omega_0) : T \rightarrow \mathbb{R}$$

az $X(t; \omega) : T \times \Omega \rightarrow \mathbb{R}$ sztochasztikus folyamat ω_0 kimenetel melletti **trajektóriája**.

1.1.8. Definíció.

$$X(n; \omega) = X_n(\omega) : \mathbb{N} \times \Omega \rightarrow I$$

diszkrét idejű sztochasztikus folyamat (diszkrét idejű) **Markov-lánc/Markov-folyamat**, ha **Markov-tulajdonságú**, azaz

$$A_n = \sigma(X_0, X_1, \dots, X_n)$$

esetén $\forall B \in \mathbb{B}_I, \forall m \geq n$ -re

$$(P(X_m \in B | X_0, X_1, \dots, X_n) =) P(X_m \in B | A_n) = P(X_m \in B | X_n)$$

1.1.9. Definíció.

$$X_t(\omega) = X(t; \omega) : [0, \infty] \times \Omega \rightarrow I$$

folytonos idejű sztochasztikus folyamat (folytonos idejű) **Markov-folyamat**, ha **Markov-tulajdonságú**, azaz

$$A_{t_0} = \sigma(\{X_t\}_{t \leq t_0})$$

esetén $\forall B \in \mathbb{B}_I, \forall t_1 \geq t_0$ -ra

$$P(X_{t_1} \in B | A_{t_0}) = P(X_{t_1} \in B | X_{t_0})$$

1.1.10. Definíció. $(X_n)_n$ Markov-lánc homogén/stacionárius, ha a $P(X_{n+1} = j | X_n = i)$ feltételes valószínűség minden n -re ugyanannyi, ekkor előbbi valószínűségekre a p_{ij} jelölést használjuk.

1.1.11. Definíció. Legyen adott egy $(X_n)_n$ diszkrét idejű homogén Markov folyamat Ekkor a

$$P = (p_{ij})_{i,j \in I}$$

mátrix a

$$p_{ij} = P(X_{n+1} = j | X_n = i)$$

egylépéses átmenetvalószínűségek mátrixa.

1.1.12. Megjegyzés. Előfordulhat, hogy $|I|$ megszámlálhatóan végtelen; ekkor szintén a mátrix megnevezés használjuk.

X_0 valószínűségi eloszlása a kezdeti eloszlás. X_0 -nak $\mu = (\mu_i)_{i \in I}$ eloszlására a Markov-tulajdonság miatt

$$\begin{aligned} & P(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) \\ &= P(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdot P(X_0 = i_1, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \\ &= P(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdot \\ &\cdot P(X_{n-1} = i_{n-1} | X_0 = i_0, X_1 = i_1, \dots, X_{n-2} = i_{n-2}) \cdot \dots \cdot P(X_1 = i_1 | X_0 = i_0) \cdot P(X_0 = i_0) \\ &= p_{i_{n-1}i_n} \cdot \dots \cdot p_{i_0i_1} \cdot \mu_{i_0} \end{aligned}$$

Tehát a kezdeti eloszlás és annak átmenetmátrixa meghatározza a Markov-láncot.

Legyen $m \in \mathbb{N}^+$ tetszőleges, jelölje $p_{ij}^{(n)} = P(X_{n+m} = j | X_n = i)$ az n -lépéses átmenetvalószínűségeket (ezek a homogenitás miatt m -től függetlenek).

1.1.13. Állítás. (*Chapman-Kolmogorov egyenlőség*):

$$p_{ij}^{(n+m)} = \sum_{k \in I} p_{ik}^{(n)} \cdot p_{kj}^{(m)}$$

Bizonyítás. $P(X_{n+m} = j, X_n = k) = P(X_n = k) \cdot P(X_{n+m} = j | X_n = k)$ miatt

$$\begin{aligned} P(X_{n+m} = j | X_0 = i) &= \sum_{k \in I} P(X_{n+m} = j, X_n = k | X_0 = i) \\ &= \sum_{k \in I} P(X_n = k | X_0 = i) \cdot P(X_{n+m} = j | X_n = k, X_0 = i) = \sum_{k \in I} p_{ik}^{(n)} \cdot p_{kj}^{(m)} \end{aligned}$$

□

1.1.14. Következmény. $P^n = (p_{ij}^{(n)})_{i,j \in I}$, vagyis az n -lépéses átmenetvalószínűségek mátrixa éppen P^n .

1.2. Rejtett Markov-modell

1.2.1. Definíció. Legyen $X_n = X(n, \omega_X)$ diszkrét idejű Markov-lánc, $Y_n = Y(n, \omega_Y)$ diszkrét idejű sztochasztikus folyamat. Ekkor (X_n, Y_n) sorozat (rejtett) **Markov-modell**, ha $\forall n$ -re $\forall x_1, \dots, x_n$ -re $\forall A$ Borel-halmazra

$$P(Y_n \in A | X_1 = x_1, \dots, X_n = x_n) = P(Y_n \in A | X_n = x_n)$$

1.2.2. Definíció. Legyen $X_t = X(t, \omega_X)$ folytonos idejű Markov-lánc, $Y_t = Y(t, \omega_Y)$ folytonos idejű sztochasztikus folyamat. Ekkor $(X_t, Y_t)_{t \geq 0}$ (rejtett) **Markov-modell**, ha $\forall t_0 \in [0, \infty)$ -re $\forall A \in B(I_Y)$ Borel-halmazra

$$P(Y_{t_0} \in A | \sigma(\{X_t : t \leq t_0\})) = P(Y_{t_0} \in A | \sigma(X_{t_0}))$$

Gyakorlatban X_n viselkedése nem közvetlenül megfigyelhető (ezért rejtett), emiatt szükségünk van annak becslésére; diszkrét esetben a feladatot érdemes irányított gráfként ábrázolni, ahol a két pontosztály az X_n -ek és az Y_n -ek, ahol $\forall X_n$ -ből $\forall X_m$ -be vezet él $P(X_n \rightarrow X_m)$ súlyozással, továbbá $\forall Y_k$ -ba $P(Y_k | X_n)$ súlyozással ($n, m, k \in \mathbb{N}^+$ tetszőleges), felvéve egy Start csúcsot, melyből X_n -ekbe vezet él a kezdeti eloszlásnak megfelelően.

Az X_n -ek becslésére itt bemutatott módszer megköveteli az eloszlások típusának ismeretét.

2. fejezet

Markov-láncok becslése

2.1. Expectation-Maximization algoritmus

Gyakorlatban sokszor az eloszlás bonyolult formája miatt nehéz ML-becslést adni egy rejtett Markov-modellhez tartozó eloszlás paraméterére, ezért azt közelítenünk kell. Egy lehetséges közelítés megadására szolgál a következő algoritmus:

Legyen adott egy (diszkrét idejű) $(X_n, Y_n)_{(1 \leq n \leq m)}$ rejtett Markov-modell, a megfigyelések $y = (y_1, \dots, y_m)$, azokhoz tartozó rejtett állapotok $x = (x_1, \dots, x_m)$, az eloszlás

$$(X, Y) \sim p((x, y)|\theta) = p_\theta(x, y) = \exp(\eta(\theta) \cdot s(x, y)) \cdot h(x, y)/c(\theta),$$

ahol η monoton függvény, $\Theta \subseteq \mathbb{R}^n$ nyílt halmaz a vizsgált eloszlástípus lehetséges paramétereinek halmaza,

$$s : \mathbb{R}^d \rightarrow \mathbb{R}^k$$

elégseges statisztika,

$$h : \mathbb{R}^d \rightarrow \mathbb{R}^{\geq 0},$$

$$c : \Theta \rightarrow \mathbb{R}^{\geq 0}$$

normalizáló függvény. Tehát

$$c(\theta) = \int_{(X,Y)} (\exp(\eta(\theta) \cdot s(x, y)) \cdot h(x, y)) d(x, y)$$

Célünk egy $\theta_{MLE} \in \Theta$ megadása, melyre

$$\theta_{MLE} \in \operatorname{argmax}_\theta (p_\theta(y)),$$

vagyis maximalizálja a

$$p(\theta) = p_\theta(y) = \int p_\theta(x, y) dx$$

peremeloszlás likelihood-függvényét (legalábbis elég jól közelíti egy globális maximum-helyét). Feltehető tehát, hogy $\eta(\theta) = \theta$.

2.1.1. Állítás. $\nabla \log(c(\theta)) = E_\theta s(x, y)$

Bizonyítás. $\forall j$ -re

$$\begin{aligned} (\delta/\delta\theta_j) \log(c(\theta)) &= 1/c(\theta) \cdot (\delta/\delta\theta_j) c(\theta) \\ &= 1/c(\theta) \int s_j(x, y) p_\theta(x) d(x, y) = E_\theta s_j(x, y) \end{aligned}$$

(feltettük hogy a deriválás és az integrálás felcserélhető)

□

2.1.2. Következmény. θ a likelihood függvény szélsőértéke

$$\Rightarrow E_{\theta}(s(X, Y)|Y = y) = E_{\theta}(s(X, Y))$$

Bizonyítás.

$$\begin{aligned} 0 &= (\delta/\delta\theta_i)\log(p_{\theta}(y)) = 1/p(\theta) \cdot \int (\delta/\delta\theta_i)p_{\theta}(x, y)dx \\ &= 1/p(\theta) \cdot \int (\delta/\delta\theta_i)\exp(\theta s(x, y) - \log(c(\theta))) \cdot h(x, y)dx \\ &= 1/p(\theta) \cdot \int (s_i(x, y) - (\delta/\delta\theta_i)\log(c(\theta))) \cdot p_{\theta}(x, y) \\ &= 1/p(\theta) \cdot \int (s_i(x, y) - E_{\theta}s_i(X, Y)) \cdot p_{\theta}(x, y) \\ &= \int s_i(x, y) \cdot p_{\theta}(x|y) - E_{\theta}s_i(X, Y) \\ &= E_{\theta}(s_i(X, Y)|Y = y) - E_{\theta}s_i(X, Y) \iff E_{\theta}(s(X, Y)|Y = y) = E_{\theta}(s(X, Y)) \end{aligned}$$

□

Legyen $\forall t$ -re

$$Q(\theta|\theta_t) = E_{\theta_t}(\log(p_{\theta}(X, Y))|Y = y)$$

Az algoritmus ötlete hogy kiindulunk tetszőleges $\theta_0 \in \Theta$ becslésből és minden iterációban javítunk rajta úgy, hogy megoldjuk a

$$\theta_{t+1} = \operatorname{argmax}_{\theta} Q(\theta|\theta_t) (\geq \theta_t)$$

rekurziót. Vegyük észre hogy 2.1.1 miatt

$$\begin{aligned} \nabla Q(\theta|\theta_t) &= \nabla(\theta \cdot E_{\theta_t}(s(X, Y)|Y = y) - \log(c(\theta)) - \text{konstans}) \\ &= E_{\theta_t}(s(X, Y)|Y = y) - E_{\theta}(s(X, Y)) \end{aligned}$$

Az eredeti rekurzió megoldásához tehát megoldandó az

$$E_{\theta_{t-1}}(s(X, Y)|Y = y) = E_{\theta_t}(s(X, Y))$$

rekurzió.

Konyhaszabály: addig iteráljuk mígnem rögzített t -re $E_{\theta_t}(s(X, Y)|Y = y)$ és $E_{\theta_t}(s(X, Y))$ majdnem egyenlő (mondjuk az eltérésük $< 10^{-5}$), ekkor ugyanis a becslés előbbi következmény miatt közelít egy szélsőértékhez. A konvergencia abból adódik, hogy a θ_t -khez tartozó értékekből alkotott sorozat monoton és korlátos, márpedig az

$$E_{\theta_{t-1}}(s(X, Y)|Y = y) = E_{\theta_t}(s(X, Y))$$

rekurzió miatt és mert

$$Q(\theta|\theta_t) = E_{\theta_t}(\log(p_{\theta}(X, Y))|Y = y)$$

sorozat konvergens, adódik hogy $\exists t$: $E_{\theta_t}(s(X, Y)|Y = y)$ és $E_{\theta_t}(s(X, Y))$ majdnem egyenlő (mert a tagokból alkotott sorozatoknak ugyanaz a határértéke).

A kapott szélsőérték nem feltétlen globális maximum, ennek érdekében különböző θ_0 kezdőértékekből kell indítanunk az algoritmust. A legjobb becslést globális maximumnak feltételezzük.

2.2. Bayes-filter

Az EM-algoritmusban szereplő rejtett Markov-modellben nem ismerjük a

$$p_\theta(X, Y|Y = y)$$

értékeket, emiatt szeretnénk azokat közelíteni. Egy lehetséges közelítés megadására szolgál a Bayes-filter:

Tegyük fel hogy a rejtett Markov-modellt leíró egyenletrendszer

$$X_k = f(X_{k-1}, u_k, w_k)$$

$$Y_k = g(X_k, n_k)$$

alakú, ahol $u_k \in \mathbb{R}^N$ control input, w_k és n_k zajok. Célunk becslést adni a

$$bel(X_k) = p(X_k|u_{1:k}, Y_{1:k})$$

valószínűségekre, ehhez megadunk egy rekurziót. Nyilván $bel(X_0) = p(X_0)$.

2.2.1. Lemma.

$$p(x|y, z) = p(y|x, z) \cdot p(x|z)/p(y|z)$$

Bizonyítás.

$$\begin{aligned} & p(y|x, z) \cdot p(x|z)/p(y|z) \\ &= p(y|x, z) \cdot p(x, z)/(p(z) \cdot p(y|z)) = p(y|z, x) \cdot p(z, x)/p(y, z) \\ &= p(x, y, z)/p(y, z) = p(x|y, z) \end{aligned}$$

□

2.2.2. Állítás. $\exists \eta$ konstans amire

$$bel(X_k) = \eta p(Y_k|X_k) \int p(X_k|X_{k-1}, u_k) \cdot bel(X_{k-1}) dX_{k-1}$$

Bizonyítás. Előbbi lemma és a Markov-tulajdonság miatt

$$\begin{aligned} bel(X_k) &= p(X_k|u_{1:k}, Y_{1:k}) \\ &= p(Y_k|X_k, u_{1:k}, Y_{1:k-1}) \cdot p(X_k|u_{1:k}, Y_{1:k-1})/p(Y_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta p(Y_k|X_k, u_{1:k}, Y_{1:k-1}) \cdot p(X_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta p(Y_k|X_k) \cdot p(X_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta p(Y_k|X_k) \cdot \int p(X_k, X_{k-1}|u_{1:k}, Y_{1:k-1}) dX_{k-1} \\ &= \eta p(Y_k|X_k) \cdot \int p(X_k|X_{k-1}, u_{1:k}, Y_{1:k-1}) \cdot p(X_{k-1}|u_{1:k}, Y_{1:k-1}) dX_{k-1} \\ &= \eta p(Y_k|X_k) \cdot \int p(X_k|X_{k-1}, u_k) \cdot p(X_{k-1}|u_{1:k-1}, Y_{1:k-1}) dX_{k-1} \\ &= \eta p(Y_k|X_k) \int p(X_k|X_{k-1}, u_k) \cdot bel(X_{k-1}) dX_{k-1} \end{aligned}$$

□

3. fejezet

Diszkrét állapotterű rejtett Markov-modell

3.1. Forward-Backward algoritmus