
Madár Patrik

Markov-láncok

Folyamatosan frissülő jegyzet

Budapest, 2026

Tartalomjegyzék

1. Fogalmak	3
1.1. Markov-láncok bevezetése	3
1.2. Rejtett Markov-modell	5
2. Markov-láncok becslése	6
2.1. Expectation-Maximization algoritmus	6
2.2. Bayes-filter	8
3. Diszkrét állapotterű rejtett Markov-modell	9
3.1. Forward-Backward algoritmus	9
3.2. A Baum-Welch algoritmus	11
4. Folytonos állapotterű rejtett Markov-modell	13
4.1. A Bayes-filter általános esete	13
4.2. A Kalman-szűrő	14

1. fejezet

Fogalmak

1.1. Markov-láncok bevezetése

1.1.1. Definíció. Legyen adott elemi események Ω halmazán értelmezett A σ -algebra. Ekkor (Ω, A) -t mérhető térnek, és $\mu : A \rightarrow [0; \infty]$ -t mértéknek nevezzük, ha $\mu(\emptyset) = 0$ és diszjunkt $A_i \in A$ -kra

$$\mu\left(\bigcup A_i\right) = \sum \mu(A_i),$$

végül az (Ω, A, μ) rendezett hármast mértéktérnek nevezzük.

1.1.2. Definíció. Azt a legszűkebb σ -algebrát, ami tartalmazza $\mathbb{R}$ nyílt részhalmazait, Borel-mérhető halmazok rendszerének nevezzük, melynek elemei a Borel-mérhető halmazok (ha az alaphalmaz nem $\mathbb{R}$, akkor az adott topologikus tér nyílt halmazait tartalmazó legszűkebb σ -algebra).

1.1.3. Definíció. (Ω, A) mérhető téren értelmezett $f : \Omega \rightarrow \mathbb{R}$ függvény mérhető függvény, ha $\forall \mathbb{R}$ -ben Borel-mérhető halmaz f általi ösképe mérhető, azaz $\in A$. Ha $P : A \rightarrow [0; 1]$ mérték, melyre $P(\Omega) = 1$, akkor az (Ω, A, P) hármast valószínűségi mezőnek nevezzük.

1.1.4. Definíció. (Ω, A, P) valószínűségi mező Ω eseményterén értelmezett $X : \Omega \rightarrow \mathbb{R}$ függvény valószínűségi változó (ez a hivatalos definíció), ha $\forall x \in \mathbb{R}$ -re

$$\{\omega \in \Omega : X(\omega) \leq x\} \in A$$

1.1.5. Megjegyzés. Általában valós/vektorértékű valószínűségi változón egy (Ω, A, P) valószínűségi mezőn definiált $(\mathbb{R}^n, \mathbb{B}^n)$ értékű mérhető függvényt értünk, ahol $\mathbb{B}^n$ az $\mathbb{R}^n$ -ben Borel-mérhető halmazok σ -algebrája. Külön kikötés hiányában I halmaz Borel-halmazait $\mathbb{B}_I$ vagy $\mathbb{B}$ jelöli (utóbbi csak akkor, ha a jelölés egyértelmű).

1.1.6. Definíció. Az (Ω, A, P) valószínűségi mezőn értelmezett X valószínűségi változó eloszlásfüggvénye $F_X : \mathbb{R} \rightarrow \mathbb{R}$, $F_X(x) = P(X < x)$. $f : \mathbb{R} \rightarrow \mathbb{R}$ az X abszolút folytonos valószínűségi változó sűrűségfüggvénye, ha $F_X(x) = \int_{-\infty}^x f(t)dt$.

1.1.7. Definíció. Az (Ω, A, P) valószínűségi mezőn és annak T időhalmazán értelmezett

$$X(t, \omega) : T \times \Omega \rightarrow \mathbb{R}$$

kétváltozós függvény **sztochasztikus folyamat**, ha $\forall$ rögzített $t \in T$ -re $X(t, \omega)$ az (Ω, A, P) valószínűségi mezőn értelmezett valószínűségi változó. Az $X(t; \omega)$ a $T = \mathbb{N}$ esetben diszkrét idejű, $T = [0; \infty)$ esetben folytonos idejű sztochasztikus folyamat. Rögzített $\omega_0 \in \Omega$ -ra

$$X(t, \omega_0) : T \rightarrow \mathbb{R}$$

az $X(t; \omega) : T \times \Omega \rightarrow \mathbb{R}$ sztochasztikus folyamat ω_0 kimenetel melletti **trajektóriája**.

1.1.8. Definíció.

$$X(n; \omega) = X_n(\omega) : \mathbb{N} \times \Omega \rightarrow I$$

diszkrét idejű sztochasztikus folyamat (diszkrét idejű) **Markov-lánc/Markov-folyamat**, ha **Markov-tulajdonságú**, azaz

$$A_n = \sigma(X_0, X_1, \dots, X_n)$$

esetén $\forall B \in \mathbb{B}_I, \forall m \geq n$ -re

$$(P(X_m \in B | X_0, X_1, \dots, X_n) =) P(X_m \in B | A_n) = P(X_m \in B | X_n)$$

1.1.9. Definíció.

$$X_t(\omega) = X(t; \omega) : [0, \infty] \times \Omega \rightarrow I$$

folytonos idejű sztochasztikus folyamat (folytonos idejű) **Markov-folyamat**, ha **Markov-tulajdonságú**, azaz

$$A_{t_0} = \sigma(\{X_t\}_{t \leq t_0})$$

esetén $\forall B \in \mathbb{B}_I, \forall t_1 \geq t_0$ -ra

$$P(X_{t_1} \in B | A_{t_0}) = P(X_{t_1} \in B | X_{t_0})$$

1.1.10. Definíció. $(X_n)_n$ Markov-lánc homogén/stacionárius, ha a $P(X_{n+1} = j | X_n = i)$ feltételes valószínűség minden n -re ugyanannyi, ekkor előbbi valószínűségekre a p_{ij} jelölést használjuk.

1.1.11. Definíció. Legyen adott egy $(X_n)_n$ diszkrét idejű homogén Markov folyamat Ekkor a

$$P = (p_{ij})_{i,j \in I}$$

mátrix a

$$p_{ij} = P(X_{n+1} = j | X_n = i)$$

egylépéses átmenetvalószínűségek mátrixa.

1.1.12. *Megjegyzés.* Előfordulhat, hogy $|I|$ megszámlálhatóan végtelen; ekkor szintén a mátrix megnevezés használjuk.

X_0 valószínűségi eloszlása a kezdeti eloszlás. X_0 -nak $\mu = (\mu_i)_{i \in I}$ eloszlására a Markov-tulajdonság miatt

$$\begin{aligned} & P(X_0 = i_0, X_1 = i_1, \dots, X_n = i_n) \\ &= P(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdot P(X_0 = i_1, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \\ &= P(X_n = i_n | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}) \cdot \\ &\cdot P(X_{n-1} = i_{n-1} | X_0 = i_0, X_1 = i_1, \dots, X_{n-2} = i_{n-2}) \cdot \dots \cdot P(X_1 = i_1 | X_0 = i_0) \cdot P(X_0 = i_0) \\ &= p_{i_{n-1}i_n} \cdot \dots \cdot p_{i_0i_1} \cdot \mu_{i_0} \end{aligned}$$

Tehát a kezdeti eloszlás és annak átmenetmátrixa meghatározza a Markov-láncot.

Legyen $m \in \mathbb{N}^+$ tetszőleges, jelölje $p_{ij}^{(n)} = P(X_{n+m} = j | X_n = i)$ az n -lépéses átmenetvalószínűségeket (ezek a homogenitás miatt m -től függetlenek).

1.1.13. Állítás. (*Chapman-Kolmogorov egyenlőség*):

$$p_{ij}^{(n+m)} = \sum_{k \in I} p_{ik}^{(n)} \cdot p_{kj}^{(m)}$$

Bizonyítás. $P(X_{n+m} = j, X_n = k) = P(X_n = k) \cdot P(X_{n+m} = j | X_n = k)$ miatt

$$\begin{aligned} P(X_{n+m} = j | X_0 = i) &= \sum_{k \in I} P(X_{n+m} = j, X_n = k | X_0 = i) \\ &= \sum_{k \in I} P(X_n = k | X_0 = i) \cdot P(X_{n+m} = j | X_n = k, X_0 = i) = \sum_{k \in I} p_{ik}^{(n)} \cdot p_{kj}^{(m)} \end{aligned}$$

□

1.1.14. Következmény. $P^n = (p_{ij}^{(n)})_{i,j \in I}$, vagyis az n -lépéses átmenetvalószínűségek mátrixa éppen P^n .

1.2. Rejtett Markov-modell

1.2.1. Definíció. Legyen $X_n = X(n, \omega_X)$ diszkrét idejű Markov-lánc, $Y_n = Y(n, \omega_Y)$ diszkrét idejű sztochasztikus folyamat. Ekkor (X_n, Y_n) sorozat (rejtett) **Markov-modell**, ha $\forall n$ -re $\forall x_1, \dots, x_n$ -re $\forall A$ Borel-halmazra

$$P(Y_n \in A | X_1 = x_1, \dots, X_n = x_n) = P(Y_n \in A | X_n = x_n)$$

1.2.2. Definíció. Legyen $X_t = X(t, \omega_X)$ folytonos idejű Markov-lánc, $Y_t = Y(t, \omega_Y)$ folytonos idejű sztochasztikus folyamat. Ekkor $(X_t, Y_t)_{t \geq 0}$ (rejtett) **Markov-modell**, ha $\forall t_0 \in [0, \infty)$ -re $\forall A \in B(I_Y)$ Borel-halmazra

$$P(Y_{t_0} \in A | \sigma(\{X_t : t \leq t_0\})) = P(Y_{t_0} \in A | \sigma(X_{t_0}))$$

Gyakorlatban X_n viselkedése nem közvetlenül megfigyelhető (ezért rejtett), emiatt szükségünk van annak becslésére; diszkrét esetben a feladatot érdemes irányított gráfként ábrázolni, ahol a két pontosztály az X_n -ek és az Y_n -ek, ahol $\forall X_n$ -ből $\forall X_m$ -be vezet él $P(X_n \rightarrow X_m)$ súlyozással, továbbá $\forall Y_k$ -ba $P(Y_k | X_n)$ súlyozással ($n, m, k \in \mathbb{N}^+$ tetszőleges), felvéve egy Start csúcsot, melyből X_n -ekbe vezet él a kezdeti eloszlásnak megfelelően.

Az X_n -ek becslésére itt bemutatott módszer megköveteli az eloszlások típusának ismeretét.

2. fejezet

Markov-láncok becslése

2.1. Expectation-Maximization algoritmus

Gyakorlatban sokszor az eloszlás bonyolult formája miatt nehéz ML-becslést adni egy rejtett Markov-modellhez tartozó eloszlás paraméterére, ezért azt közelítenünk kell. Egy lehetséges közelítés megadására szolgál a következő algoritmus:

Legyen adott egy (diszkrét idejű) $(X_n, Y_n)_{(1 \leq n \leq m)}$ rejtett Markov-modell, a megfigyelések $y = (y_1, \dots, y_m)$, azokhoz tartozó rejtett állapotok $x = (x_1, \dots, x_m)$, az eloszlás

$$(X, Y) \sim p((x, y)|\theta) = p_\theta(x, y) = \exp(\eta(\theta) \cdot s(x, y)) \cdot h(x, y)/c(\theta),$$

ahol η monoton függvény, $\Theta \subseteq \mathbb{R}^n$ nyílt halmaz a vizsgált eloszlástípus lehetséges paramétereinek halmaza,

$$s : \mathbb{R}^d \rightarrow \mathbb{R}^k$$

elégseges statisztika,

$$h : \mathbb{R}^d \rightarrow \mathbb{R}^{\geq 0},$$

$$c : \Theta \rightarrow \mathbb{R}^{\geq 0}$$

normalizáló függvény. Tehát

$$c(\theta) = \int_{(X,Y)} (\exp(\eta(\theta) \cdot s(x, y)) \cdot h(x, y)) d(x, y)$$

Célünk egy $\theta_{MLE} \in \Theta$ megadása, melyre

$$\theta_{MLE} \in \operatorname{argmax}_\theta (p_\theta(y)),$$

vagyis maximalizálja a

$$p(\theta) = p_\theta(y) = \int p_\theta(x, y) dx$$

peremeloszlás likelihood-függvényét (legalábbis elég jól közelíti egy globális maximum-helyét). Feltehető tehát, hogy $\eta(\theta) = \theta$.

2.1.1. Állítás. $\nabla \log(c(\theta)) = E_\theta s(x, y)$

Bizonyítás. $\forall j$ -re

$$\begin{aligned} (\delta/\delta\theta_j) \log(c(\theta)) &= 1/c(\theta) \cdot (\delta/\delta\theta_j) c(\theta) \\ &= 1/c(\theta) \int s_j(x, y) p_\theta(x) d(x, y) = E_\theta s_j(x, y) \end{aligned}$$

(feltettük hogy a deriválás és az integrálás felcserélhető)

□

2.1.2. Következmény. θ a likelihood függvény szélsőértéke

$$\Rightarrow E_{\theta}(s(X, Y)|Y = y) = E_{\theta}(s(X, Y))$$

Bizonyítás.

$$\begin{aligned} 0 &= (\delta/\delta\theta_i)\log(p_{\theta}(y)) = 1/p(\theta) \cdot \int (\delta/\delta\theta_i)p_{\theta}(x, y)dx \\ &= 1/p(\theta) \cdot \int (\delta/\delta\theta_i)\exp(\theta s(x, y) - \log(c(\theta))) \cdot h(x, y)dx \\ &= 1/p(\theta) \cdot \int (s_i(x, y) - (\delta/\delta\theta_i)\log(c(\theta))) \cdot p_{\theta}(x, y) \\ &= 1/p(\theta) \cdot \int (s_i(x, y) - E_{\theta}s_i(X, Y)) \cdot p_{\theta}(x, y) \\ &= \int s_i(x, y) \cdot p_{\theta}(x|y) - E_{\theta}s_i(X, Y) \\ &= E_{\theta}(s_i(X, Y)|Y = y) - E_{\theta}s_i(X, Y) \iff E_{\theta}(s(X, Y)|Y = y) = E_{\theta}(s(X, Y)) \end{aligned}$$

□

Legyen $\forall t$ -re

$$Q(\theta|\theta_t) = E_{\theta_t}(\log(p_{\theta}(X, Y))|Y = y)$$

Az algoritmus ötlete hogy kiindulunk tetszőleges $\theta_0 \in \Theta$ becslésből és minden iterációban javítunk rajta úgy, hogy megoldjuk a

$$\theta_{t+1} = \operatorname{argmax}_{\theta} Q(\theta|\theta_t) (\geq \theta_t)$$

rekurziót. Vegyük észre hogy 2.1.1 miatt

$$\begin{aligned} \nabla Q(\theta|\theta_t) &= \nabla(\theta \cdot E_{\theta_t}(s(X, Y)|Y = y) - \log(c(\theta)) - \text{konstans}) \\ &= E_{\theta_t}(s(X, Y)|Y = y) - E_{\theta}(s(X, Y)) \end{aligned}$$

Az eredeti rekurzió megoldásához tehát megoldandó az

$$E_{\theta_{t-1}}(s(X, Y)|Y = y) = E_{\theta_t}(s(X, Y))$$

rekurzió.

Konyhaszabály: addig iteráljuk mígnem rögzített t -re $E_{\theta_t}(s(X, Y)|Y = y)$ és $E_{\theta_t}(s(X, Y))$ majdnem egyenlő (mondjuk az eltérésük $< 10^{-5}$), ekkor ugyanis a becslés előbbi következmény miatt közelít egy szélsőértékhez. A konvergencia abból adódik, hogy a θ_t -khez tartozó értékekből alkotott sorozat monoton és korlátos, márpedig az

$$E_{\theta_{t-1}}(s(X, Y)|Y = y) = E_{\theta_t}(s(X, Y))$$

rekurzió miatt és mert

$$Q(\theta|\theta_t) = E_{\theta_t}(\log(p_{\theta}(X, Y))|Y = y)$$

sorozat konvergens, adódik hogy $\exists t$: $E_{\theta_t}(s(X, Y)|Y = y)$ és $E_{\theta_t}(s(X, Y))$ majdnem egyenlő (mert a tagokból alkotott sorozatoknak ugyanaz a határértéke).

A kapott szélsőérték nem feltétlen globális maximum, ennek érdekében különböző θ_0 kezdőértékekből kell indítanunk az algoritmust. A legjobb becslést globális maximumnak feltételezzük.

2.2. Bayes-filter

Az EM-algoritmusban szereplő rejtett Markov-modellben nem ismerjük a

$$p_\theta(X, Y|Y = y)$$

értékeket, emiatt szeretnénk azokat közelíteni. Egy lehetséges közelítés megadására szolgál a Bayes-filter:

Tegyük fel hogy a rejtett Markov-modellt leíró egyenletrendszer

$$X_k = f(X_{k-1}, u_k, w_k)$$

$$Y_k = g(X_k, n_k)$$

alakú, ahol $u_k \in \mathbb{R}^N$ control input, w_k és n_k zajok. Célunk becslést adni a

$$bel(X_k) = p(X_k|u_{1:k}, Y_{1:k})$$

valószínűségekre, ehhez megadunk egy rekurziót. Nyilván $bel(X_0) = p(X_0)$.

2.2.1. Lemma.

$$p(x|y, z) = p(y|x, z) \cdot p(x|z)/p(y|z)$$

Bizonyítás.

$$\begin{aligned} & p(y|x, z) \cdot p(x|z)/p(y|z) \\ &= p(y|x, z) \cdot p(x, z)/(p(z) \cdot p(y|z)) = p(y|z, x) \cdot p(z, x)/p(y, z) \\ &= p(x, y, z)/p(y, z) = p(x|y, z) \end{aligned}$$

□

2.2.2. Állítás. $\exists \eta$ konstans amire

$$bel(X_k) = \eta p(Y_k|X_k) \int p(X_k|X_{k-1}, u_k) \cdot bel(X_{k-1}) dX_{k-1}$$

Bizonyítás. Előbbi lemma és a Markov-tulajdonság miatt

$$\begin{aligned} bel(X_k) &= p(X_k|u_{1:k}, Y_{1:k}) \\ &= p(Y_k|X_k, u_{1:k}, Y_{1:k-1}) \cdot p(X_k|u_{1:k}, Y_{1:k-1})/p(Y_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta p(Y_k|X_k, u_{1:k}, Y_{1:k-1}) \cdot p(X_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta p(Y_k|X_k) \cdot p(X_k|u_{1:k}, Y_{1:k-1}) \\ &= \eta p(Y_k|X_k) \cdot \int p(X_k, X_{k-1}|u_{1:k}, Y_{1:k-1}) dX_{k-1} \\ &= \eta p(Y_k|X_k) \cdot \int p(X_k|X_{k-1}, u_{1:k}, Y_{1:k-1}) \cdot p(X_{k-1}|u_{1:k}, Y_{1:k-1}) dX_{k-1} \\ &= \eta p(Y_k|X_k) \cdot \int p(X_k|X_{k-1}, u_k) \cdot p(X_{k-1}|u_{1:k-1}, Y_{1:k-1}) dX_{k-1} \\ &= \eta p(Y_k|X_k) \int p(X_k|X_{k-1}, u_k) \cdot bel(X_{k-1}) dX_{k-1} \end{aligned}$$

□

3. fejezet

Diszkrét állapotterű rejtett Markov-modell

3.1. Forward-Backward algoritmus

A diszkrét idejű rejtett Markov-modellek (HMM) egyik legalapvetőbb és leggyakrabban használt algoritmus a Forward-Backward algoritmus. Ez az algoritmus lehetővé teszi, hogy egy megfigyeléssorozat ismeretében kiszámítsuk a rejtett állapotokra vonatkozó posterior valószínűségeket, valamint az EM-algoritmus E-lépéséhez szükséges mennyiségeket.

Legyen adott egy $(X_n, Y_n)_{n=1}^T$ diszkrét idejű rejtett Markov-modell, ahol $X_n \in \{1, 2, \dots, N\}$ a rejtett állapotok, $Y_n \in \{1, 2, \dots, M\}$ a megfigyelések. A modell paraméterei:

- $\pi_i = P(X_1 = i)$ a kezdeti eloszlás,
- $A_{ij} = P(X_{n+1} = j | X_n = i)$ az átmenetvalószínűségek mátrixa,
- $B_{ik} = P(Y_n = k | X_n = i)$ a kibocsátási valószínűségek mátrixa.

A modell paraméterei tehát $\theta = (\pi, A, B)$. Célunk, hogy a megfigyelések $y_{1:T} = (y_1, \dots, y_T)$ ismeretében kiszámítsuk a következő mennyiségeket:

1. A szűrt valószínűségeket: $\alpha_n(i) = P(X_n = i, y_{1:n})$
2. A simított valószínűségeket: $\beta_n(i) = P(y_{n+1:T} | X_n = i)$
3. A posterior állapotvalószínűségeket: $\gamma_n(i) = P(X_n = i | y_{1:T})$
4. Az átmenet-posteriorokat: $\xi_n(i, j) = P(X_n = i, X_{n+1} = j | y_{1:T})$

A Forward-Backward algoritmus

A Forward algoritmus rekurzívan számítja ki az $\alpha_n(i)$ mennyiségeket. Az inicializáció a teljes valószínűség tétele alapján:

$$\alpha_1(i) = P(X_1 = i, Y_1 = y_1) = P(Y_1 = y_1 | X_1 = i)P(X_1 = i) = B_{iy_1}\pi_i.$$

A rekurzióhoz alkalmazzuk a Markov-tulajdonságot:

$$\begin{aligned}\alpha_{n+1}(j) &= P(X_{n+1} = j, y_{1:n+1}) \\ &= P(y_{n+1} | X_{n+1} = j, y_{1:n}) \cdot P(X_{n+1} = j, y_{1:n}) \\ &= B_{jy_{n+1}} \sum_{i=1}^N P(X_{n+1} = j | X_n = i) \cdot P(X_n = i, y_{1:n}) \\ &= B_{jy_{n+1}} \sum_{i=1}^N A_{ij} \alpha_n(i).\end{aligned}$$

Tehát a Forward algoritmus:

$$\alpha_1(i) = \pi_i \cdot B_{iy_1} \quad (\text{inicializáció}) \quad (3.1)$$

$$\alpha_{n+1}(j) = B_{jy_{n+1}} \sum_{i=1}^N \alpha_n(i) A_{ij} \quad (\text{rekurzió}) \quad (3.2)$$

A megfigyelések teljes valószínűsége az α változókból számítható:

$$P(y_{1:T}) = \sum_{i=1}^N \alpha_T(i)$$

A Backward algoritmus rekurzívan számítja ki a $\beta_n(i)$ mennyiségeket. Az inicializáció triviális: $P(\emptyset|X_T = i) = 1$, tehát $\beta_T(i) = 1$. A rekurzióhoz:

$$\begin{aligned} \beta_n(i) &= P(y_{n+1:T}|X_n = i) \\ &= \sum_{j=1}^N P(X_{n+1} = j, y_{n+1:T}|X_n = i) \\ &= \sum_{j=1}^N P(X_{n+1} = j|X_n = i) \cdot P(y_{n+1:T}|X_{n+1} = j) \\ &= \sum_{j=1}^N A_{ij} \cdot P(y_{n+1}|X_{n+1} = j) \cdot P(y_{n+2:T}|X_{n+1} = j) \\ &= \sum_{j=1}^N A_{ij} B_{jy_{n+1}} \beta_{n+1}(j). \end{aligned}$$

Tehát a Backward algoritmus:

$$\beta_T(i) = 1 \quad (\text{inicializáció}) \quad (3.3)$$

$$\beta_n(i) = \sum_{j=1}^N A_{ij} B_{jy_{n+1}} \beta_{n+1}(j) \quad (\text{rekurzió}) \quad (3.4)$$

A posteriori állapot- és átmenetvalószínűségek

Az α és β változók segítségével kiszámíthatjuk a $\gamma_n(i)$ posterior állapotvalószínűségeket. A Bayes-tétel és a feltételes függetlenség miatt:

$$\begin{aligned} P(X_n = i|y_{1:T}) &= \frac{P(X_n = i, y_{1:T})}{P(y_{1:T})} \\ &= \frac{P(X_n = i, y_{1:n}) \cdot P(y_{n+1:T}|X_n = i)}{P(y_{1:T})} \\ &= \frac{\alpha_n(i) \beta_n(i)}{P(y_{1:T})}. \end{aligned}$$

Tehát:

$$\gamma_n(i) = P(X_n = i|y_{1:T}) = \frac{\alpha_n(i) \beta_n(i)}{\sum_{j=1}^N \alpha_T(j)}$$

Az átmenet-posteriorokhoz a Bayes-tétel és a Markov-tulajdonság alkalmazásával:

$$\begin{aligned} P(X_n = i, X_{n+1} = j, y_{1:T}) &= P(X_n = i, y_{1:n}) \cdot P(X_{n+1} = j|X_n = i) \\ &\quad \cdot P(y_{n+1}|X_{n+1} = j) \cdot P(y_{n+2:T}|X_{n+1} = j) \\ &= \alpha_n(i) \cdot A_{ij} \cdot B_{jy_{n+1}} \cdot \beta_{n+1}(j). \end{aligned}$$

Osztva $P(y_{1:T})$ -vel:

$$\xi_n(i, j) = P(X_n = i, X_{n+1} = j|y_{1:T}) = \frac{\alpha_n(i) A_{ij} B_{jy_{n+1}} \beta_{n+1}(j)}{\sum_{k=1}^N \alpha_T(k)}$$

3.2. A Baum-Welch algoritmus

A Baum-Welch algoritmus az EM-algoritmus speciális esete rejtett Markov-modellek paraméterbecslésére. Az újrabecslési formulák intuitív jelentése:

- $\pi_i^{\text{new}} = \gamma_1(i)$: az i . állapot várható kezdeti valószínűsége,
- $A_{ij}^{\text{new}} = \frac{\sum_{n=1}^{T-1} \xi_n(i, j)}{\sum_{n=1}^{T-1} \gamma_n(i)}$: az i -ből j -be történő átmenetek várható száma osztva az i -ből történő kilépések várható számával,
- $B_{ik}^{\text{new}} = \frac{\sum_{n=1}^T \gamma_n(i) \cdot I(y_n = k)}{\sum_{n=1}^T \gamma_n(i)}$: a k . megfigyelés várható száma az i . állapotban osztva az i . állapotban töltött várható idővel.

Formálisan:

$$\pi_i^{\text{new}} = \gamma_1(i) \quad (3.5)$$

$$A_{ij}^{\text{new}} = \frac{\sum_{n=1}^{T-1} \xi_n(i, j)}{\sum_{n=1}^{T-1} \gamma_n(i)} \quad (3.6)$$

$$B_{ik}^{\text{new}} = \frac{\sum_{n=1}^T \gamma_n(i) \cdot I(y_n = k)}{\sum_{n=1}^T \gamma_n(i)} \quad (3.7)$$

A Baum-Welch algoritmus monoton növeli a megfigyelések log-likelihoodjét:

$$P(y_{1:T}|\theta^{\text{new}}) \geq P(y_{1:T}|\theta)$$

és konvergál egy lokális maximumhoz. A bizonyítás az EM-algoritmus általános konvergenciátételén alapul.

Gyakorlati implementáció és numerikus stabilitás

A Forward-Backward algoritmus teljes implementációja az alábbi lépésekből áll:

1. **Forward lépés:** Számítsuk ki $\alpha_1(i)$ -t minden i -re, majd rekurzívan $\alpha_n(i)$ -t $n = 2, \dots, T$ -ig.
2. **Backward lépés:** Számítsuk ki $\beta_T(i)$ -t minden i -re, majd rekurzívan $\beta_n(i)$ -t $n = T - 1, \dots, 1$ -ig.
3. **Posteriorok számítása:** Számítsuk ki $\gamma_n(i)$ -t és $\xi_n(i, j)$ -t minden n, i, j -re.
4. **Újrabecslés:** Frissítsük a paramétereket a Baum-Welch formulákkal.

Az algoritmus számítási komplexitása $O(T \cdot N^2)$, ahol T az időlépések száma és N az állapotok száma.

A Forward-Backward algoritmus gyakorlati implementációja során numerikus problémák léphetnek fel, mivel az $\alpha_n(i)$ és $\beta_n(i)$ értékek exponenciálisan csökkennek n -nel. A skálázott Forward-Backward algoritmusban az α és β értékeket normalizáljuk minden lépésben:

$$\hat{\alpha}_n(i) = \frac{\alpha_n(i)}{\sum_{j=1}^N \alpha_n(j)}, \quad \hat{\beta}_n(i) = \frac{\beta_n(i)}{\sum_{j=1}^N \beta_n(j)}$$

A skálázott változókkal a posterior valószínűségek:

$$\gamma_n(i) = \hat{\alpha}_n(i) \hat{\beta}_n(i)$$

és a skálázási faktorok szorzata adja a megfigyelések log-likelihoodjét:

$$\log P(y_{1:T}) = \sum_{n=1}^T \log c_n, \quad c_n = \sum_{j=1}^N \alpha_n(j)$$

3.2.1. *Megjegyzés.* A Forward-Backward algoritmus szoros kapcsolatban áll más valószínűségi következtetési módszerekkel. A **Viterbi-algoritmus** az állapotok legvalószínűbb sorozatát keresi ($\arg \max_{x_{1:T}} P(x_{1:T}|y_{1:T})$). A **Kalman-szűrő** a Forward-Backward folytonos állapotterű megfelelője lineáris Gauss-modellekben. A **particieszűrő** pedig a nem-lineáris, nem-Gauss esetekre általánosítja ezt az elvet.

3.2.2. *Megjegyzés.* Pénzügyi alkalmazásokban a HMM-eket gyakran használják piaci rezsimek (pl. "nyugodt", "volatilis", "válság") azonosítására. A Forward-Backward algoritmus segítségével meghatározhatjuk, hogy az egyes időpontokban melyik rezsim volt a valószínűbb, becsülhetjük az állapotátmenetek valószínűségeit (pl. mennyire valószínű, hogy egy emelkedő trend után csökkenő következik), és predikciót készíthetünk a következő időpontbeli állapotról.

Pénzügyi alkalmazás: Piaci rezsim azonosítása.

A HMM-eket és a Forward-Backward algoritmust széles körben használják a pénzpiacok rejtett állapotainak (rezsimeknek) azonosítására. Tegyük fel, hogy egy részvényindex (pl. S&P 500) napi hozamait két rejtett állapottal modellezzük:

- $X_t = 1$: "nyugodt" piac (alacsony volatilitás, pozitív várható hozam)
- $X_t = 2$: "volatilis" piac (magas volatilitás, negatív vagy nulla várható hozam)

A megfigyelések Y_t a napi hozamok, amelyeket feltételes normális eloszlással modellezünk:

$$Y_t|X_t = i \sim \mathcal{N}(\mu_i, \sigma_i^2), \quad i = 1, 2$$

A Baum-Welch algoritmus segítségével becsülhetjük a modell paramétereit ($\pi, A, \mu_1, \sigma_1, \mu_2, \sigma_2$) a historikus adatokból. A Forward-Backward algoritmus minden időpontra kiszámítja a $\gamma_t(i) = P(X_t = i|y_{1:T})$ posterior valószínűségeket, azaz annak valószínűségét, hogy az adott napon melyik rezsim volt jelen.

Gyakorlati haszon:

1. A rezsimvalószínűségek segítségével dinamikusan módosíthatjuk a portfólió kockázati kitettségét (magas volatilitás esetén csökkentjük a részvénykitettséget).
2. Az átmenetvalószínűségek (A_{12}) előrejelzést adnak arra, hogy mennyire valószínű egy rezsimváltás.
3. A modell segítségével rezsim-függő VaR (Value at Risk) becslés készíthető.

Pénzügyi alkalmazás: Rezsinváltós modellek kalibrációja.

A Baum-Welch algoritmus (az EM speciális esete) a rezsinváltós modellek paramétereinek becslésére használható. A gyakorlatban:

1. **Adatok előkészítése:** Historikus hozam adatok (pl. napi S&P 500 hozamok).
2. **Rezsimek meghatározása:** Döntsük el, hány rejtett állapotot (rezsimet) feltételezünk (pl. 2: nyugodt és volatilis, vagy 3: növekvő, oldallazó, csökkenő).
3. **Inicializálás:** Adjunk kezdeti értékeket a paramétereknek (π, A, μ_i, σ_i).
4. **EM iteráció:** Futtassuk a Baum-Welch algoritmust a konvergenciáig.
5. **Rezsim azonosítás:** A Forward-Backward algoritmussal számítsuk ki a $\gamma_t(i)$ posterior valószínűségeket.
6. **Használat:** A rezsimvalószínűségek segítségével dinamikus portfólióallokáció, kockázatkezelés vagy kereskedési stratégiák.

A Baum-Welch algoritmus előnye, hogy garantáltan növeli a likelihood-ot minden iterációban, így konvergens becslést ad.

4. fejezet

Folytonos állapotterű rejtett Markov-modell

4.1. A Bayes-filter általános esete

A Bayes-filter az előző fejezetben tárgyalt Forward-Backward algoritmus folytonos állapotterű általánosítása. Míg a diszkrét esetben az állapotok véges halmazból kerültek ki, addig folytonos állapotterű problémákban az állapotváltozók $\mathbb{R}^d$ -ben vesznek fel értékeket.

Legyen $x_t \in \mathbb{R}^n$ a rendszer állapota, u_t a beavatkozás (kontroll), z_t a megfigyelés. A Bayes-filter célja a $bel(x_t) = p(x_t|z_{1:t}, u_{1:t})$ posterior sűrűségfüggvény rekurzív számítása.

A Bayes-filter algoritmusa:

1. Predikció (control update):

$$\overline{bel}(x_t) = \int p(x_t|u_t, x_{t-1}) \cdot bel(x_{t-1}) dx_{t-1}$$

2. Korrekció (measurement update):

$$bel(x_t) = \eta \cdot p(z_t|x_t) \cdot \overline{bel}(x_t)$$

ahol η normalizációs konstans.

A fenti algoritmus elméletben minden problémára alkalmazható, de gyakorlatban csak speciális esetekben számolható zárt alakban. A két fő korlátozó tényező:

- Az integrál elvégzése a predikciós lépésben,
- A posterior sűrűségfüggvény reprezentációja.

A Markov-feltevés: A Bayes-filter helyes működéséhez feltételezzük, hogy az állapot teljes, azaz:

$$p(x_t|x_{0:t-1}, z_{1:t-1}, u_{1:t}) = p(x_t|x_{t-1}, u_t)$$
$$p(z_t|x_{0:t}, z_{1:t-1}, u_{1:t}) = p(z_t|x_t)$$

Ezek a feltételek biztosítják, hogy a múltbeli információk az aktuális állapoton keresztül fejtik ki hatásukat.

Pénzügyi alkalmazás: Market making és valódi ár becslése.

A Bayes-filter általános keretet ad a valódi eszközár becsléséhez zajos piaci adatokból. Egy market maker feladata, hogy vételi (bid) és eladási (ask) árakat határozzon meg. A valódi ár v_t nem megfigyelhető közvetlenül, de a kereskedések árából következtethetünk rá.

Modell:

$$v_t = v_{t-1} + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \sigma_v^2) \quad (4.1)$$

$$p_t = v_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma_p^2) \quad (4.2)$$

A Bayes-filter (jelen esetben a Kalman-szűrő) becslést ad a valódi árra ($\hat{v}_t$) és annak bizonytalanságára (σ_t). A market maker stratégiája:

$$bid_t = \hat{v}_t - \delta - \gamma \cdot \sigma_t \quad (4.3)$$

$$ask_t = \hat{v}_t + \delta + \gamma \cdot \sigma_t \quad (4.4)$$

ahol δ a tranzakciós költségek fedezete, γ pedig a kockázati prémium. Minél nagyobb a bizonytalanság (σ_t), annál szélesebb a bid-ask spread.

4.2. A Kalman-szűrő

A Kalman-szűrő a Bayes-filter zárt alakú megoldása lineáris Gauss-rendszerekre. Ez az egyik leggyakrabban használt szűrő a gyakorlatban, köszönhetően egyszerűségének és optimális tulajdonságainak.

Lineáris Gauss-rendszerek: A Kalman-szűrő a következő három feltevessel él:

1. Az állapotátmenet lineáris, additív Gauss-zajjal:

$$x_t = A_t x_{t-1} + B_t u_t + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, R_t)$$

2. A megfigyelési modell lineáris, additív Gauss-zajjal:

$$z_t = C_t x_t + \delta_t, \quad \delta_t \sim \mathcal{N}(0, Q_t)$$

3. A kezdeti állapot Gauss-eloszlású:

$$bel(x_0) = \mathcal{N}(x_0; \mu_0, \Sigma_0)$$

Ezek a feltételek biztosítják, hogy a posterior minden időpontban Gauss-eloszlású maradjon.

A Kalman-szűrő algoritmusa:

A szűrő a $bel(x_t)$ eloszlást a μ_t várható értékkel és a Σ_t kovarianciamátrixszal reprezentálja.

Predikciós lépés:

$$\bar{\mu}_t = A_t \mu_{t-1} + B_t u_t \quad (4.5)$$

$$\bar{\Sigma}_t = A_t \Sigma_{t-1} A_t^T + R_t \quad (4.6)$$

Korrektciós lépés:

$$K_t = \bar{\Sigma}_t C_t^T (C_t \bar{\Sigma}_t C_t^T + Q_t)^{-1} \quad (4.7)$$

$$\mu_t = \bar{\mu}_t + K_t (z_t - C_t \bar{\mu}_t) \quad (4.8)$$

$$\Sigma_t = (I - K_t C_t) \bar{\Sigma}_t \quad (4.9)$$

ahol K_t a Kalman-erősítés (Kalman gain).

A Kalman-szűrő levezetése:

A predikciós lépés a Bayes-filter predikciós képletéből származik. Mivel mindkét tényező Gauss-eloszlású, a konvolúciójuk is Gauss-eloszlású:

$$\overline{bel}(x_t) = \int \mathcal{N}(x_t; A_t x_{t-1} + B_t u_t, R_t) \cdot \mathcal{N}(x_{t-1}; \mu_{t-1}, \Sigma_{t-1}) dx_{t-1}$$

A szorzat Gauss-eloszlású, paraméterei a fenti predikciós képletek.
A korrekciós lépés a Bayes-tétel alkalmazása:

$$bel(x_t) = \eta \cdot p(z_t|x_t) \cdot \bar{bel}(x_t) = \eta \cdot \mathcal{N}(z_t; C_t x_t, Q_t) \cdot \mathcal{N}(x_t; \bar{\mu}_t, \bar{\Sigma}_t)$$

Két Gauss-eloszlás szorzata is Gauss-eloszlású, paraméterei a fenti korrekciós képletek.

A Kalman-szűrő tulajdonságai:

- **Optimalitás:** A Kalman-szűrő minimális négyzetes hiba értelemben optimális becslést ad lineáris Gauss-rendszerekben.
- **Rekurzivitás:** A szűrő csak az előző állapotbecslést és az aktuális megfigyelést használja, így online alkalmazható.
- **Komplexitás:** Minden lépés $O(n^3)$ időigényű a mátrixinverzió miatt, ahol n az állapotter dimenziója.

A Kalman-szűrő pénzügyi alkalmazásai:

A Kalman-szűrő az egyik legelterjedtebb eszköz a kvantitatív pénzügyekben:

- **Trendbecslés:** Az árfolyamok rejtett trendjének követése zajos megfigyelésekből.
- **Volatilitás modellezése:** A volatilitás mint rejtett állapot becslése.
- **Faktor timing:** A faktorstratégiák (pl. érték, növekedés) időzítése dinamikus faktor modellekkel.
- **Market making:** A valódi eszközár becslése a bid-ask spread meghatározásához.

Az Extended Kalman-szűrő (EKF)

A valós problémákban az állapotátmenet és a megfigyelési modell gyakran nemlineáris. Az Extended Kalman-szűrő (EKF) a Kalman-szűrő általánosítása nemlineáris rendszerekre.

A nemlineáris modell:

$$x_t = g(u_t, x_{t-1}) + \epsilon_t, \quad \epsilon_t \sim \mathcal{N}(0, R_t) \quad (4.10)$$

$$z_t = h(x_t) + \delta_t, \quad \delta_t \sim \mathcal{N}(0, Q_t) \quad (4.11)$$

ahol g és h nemlineáris függvények.

Linearizáció: Az EKF a nemlineáris függvényeket Taylor-sorral linearizálja az aktuális becslés körül:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t(x_{t-1} - \mu_{t-1}) \quad (4.12)$$

$$h(x_t) \approx h(\bar{\mu}_t) + H_t(x_t - \bar{\mu}_t) \quad (4.13)$$

ahol G_t és H_t a Jacobi-mátrixok:

$$G_t = \left. \frac{\partial g}{\partial x_{t-1}} \right|_{u_t, \mu_{t-1}}, \quad H_t = \left. \frac{\partial h}{\partial x_t} \right|_{\bar{\mu}_t}$$

Az EKF algoritmusai:

Predikció:

$$\bar{\mu}_t = g(u_t, \mu_{t-1}) \quad (4.14)$$

$$\bar{\Sigma}_t = G_t \Sigma_{t-1} G_t^T + R_t \quad (4.15)$$

Korrekció:

$$K_t = \bar{\Sigma}_t H_t^T (H_t \bar{\Sigma}_t H_t^T + Q_t)^{-1} \quad (4.16)$$

$$\mu_t = \bar{\mu}_t + K_t(z_t - h(\bar{\mu}_t)) \quad (4.17)$$

$$\Sigma_t = (I - K_t H_t) \bar{\Sigma}_t \quad (4.18)$$

Az EKF korlátai:

- A linearizáció csak lokálisan pontos; nagy bizonytalanság esetén hibás lehet.
- A Jacobi-mátrixok számítása analitikusan nehéz vagy numerikusan instabil lehet.
- A posterior csak közelítőleg Gauss-eloszlású.

Pénzügyi alkalmazások:

Az EKF-ot akkor használják, amikor a modell nemlineáris, például:

- Opciók árazási modellekben (pl. Black-Scholes) a volatilitás becslése,
- Kockázattertek (VaR) modellezése nemlineáris portfóliók esetén,
- Nemlineáris faktor modellek becslése.

Az Unscented Kalman-szűrő (UKF)

Az Unscented Kalman-szűrő (UKF) alternatív megközelítést kínál a nemlineáris rendszerek szűrésére. Ahelyett, hogy a nemlineáris függvényeket linearizálná, az UKF determinisztikus sigma-pontokat használ a Gauss-eloszlás reprezentálására.

Az Unscented transzformáció:

Egy n -dimenziós Gauss-eloszláshoz $2n + 1$ sigma-pontot választunk:

$$\mathcal{X}^{[0]} = \mu \quad (4.19)$$

$$\mathcal{X}^{[i]} = \mu + \left(\sqrt{(n + \lambda)\Sigma} \right)_i, \quad i = 1, \dots, n \quad (4.20)$$

$$\mathcal{X}^{[i]} = \mu - \left(\sqrt{(n + \lambda)\Sigma} \right)_{i-n}, \quad i = n + 1, \dots, 2n \quad (4.21)$$

A sigma-pontok súlyai:

$$w_m^{[0]} = \frac{\lambda}{n + \lambda} \quad (4.22)$$

$$w_c^{[0]} = \frac{\lambda}{n + \lambda} + (1 - \alpha^2 + \beta) \quad (4.23)$$

$$w_m^{[i]} = w_c^{[i]} = \frac{1}{2(n + \lambda)}, \quad i = 1, \dots, 2n \quad (4.24)$$

A sigma-pontokat átvezetjük a nemlineáris függvényen:

$$\mathcal{Y}^{[i]} = g(\mathcal{X}^{[i]})$$

majd visszanyerjük a Gauss-eloszlás paramétereit:

$$\mu' = \sum_{i=0}^{2n} w_m^{[i]} \mathcal{Y}^{[i]} \quad (4.25)$$

$$\Sigma' = \sum_{i=0}^{2n} w_c^{[i]} (\mathcal{Y}^{[i]} - \mu')(\mathcal{Y}^{[i]} - \mu')^T \quad (4.26)$$

Az UKF előnyei az EKF-fel szemben:

- Nem szükséges Jacobi-mátrixok számítása (derivált-mentes szűrő).
- Pontosabb közelítést ad erősen nemlineáris rendszerekben.
- A sigma-pontos megközelítés a Taylor-sor magasabb rendű tagjait is figyelembe veszi.

Az UKF algoritmus:

A szűrő minden lépésben:

1. Sigma-pontok generálása az aktuális becslésből.
2. A sigma-pontok átvezetése a nemlineáris állapotátmeneten.
3. A predikció kiszámítása a transzformált pontokból.
4. Új sigma-pontok generálása a predikcióból.
5. A sigma-pontok átvezetése a nemlineáris megfigyelési modellen.
6. A korrekció kiszámítása a transzformált pontokból.

Pénzügyi alkalmazások:

Az UKF-ot akkor érdemes használni, amikor:

- A modell erősen nemlineáris,
- A Jacobi-mátrixok számítása nehézkes,
- A bizonytalanság nagy, és a linearizáció pontatlanságot okozna.

Ilyen helyzet lehet például a sztochasztikus volatilitás modellek becslése, ahol a volatilitás és az árfolyam közötti kapcsolat nemlineáris.

4.2.1. *Megjegyzés.* A Kalman-szűrő család tagjai (KF, EKF, UKF) a Bayes-filter különböző közelítései. A választás a probléma jellegétől függ: lineáris Gauss-esetben a KF optimális, enyhén nemlineáris esetben az EKF elegendő, erősen nemlineáris esetben az UKF vagy a részecskeszűrő ajánlott.

4.2.2. *Megjegyzés.* Pénzügyi alkalmazásokban a Kalman-szűrő családot gyakran kombinálják más módszerekkel. Például a HMM-ekkel azonosított piaci rezsimekhez különböző Kalman-szűrőket lehet rendelni (rezsim-váltós modellek), vagy a faktorstratégiák időzítésére használják a faktorok dinamikus becslésére.

Pénzügyi alkalmazás: Trend és volatilitás becslése.

A Kalman-szűrő az egyik legelterjedtebb eszköz a kvantitatív pénzügyekben.

Trendkövetés: Legyen p_t egy eszköz árfolyama. Feltételezzük, hogy az árfolyam egy rejtett trend körül ingadozik:

$$\mu_t = \mu_{t-1} + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \sigma_\eta^2) \quad (4.27)$$

$$p_t = \mu_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma_\varepsilon^2) \quad (4.28)$$

Ez a modell Kalman-szűrő formában: $x_t = \mu_t$, $A_t = 1$, $R_t = \sigma_\eta^2$, $C_t = 1$, $Q_t = \sigma_\varepsilon^2$. A szűrő minden időpontban becslést ad a trendre (μ_t) és annak bizonytalanságára (σ_μ^2).

Volatilitás becslése: A sztochasztikus volatilitás modellekben a log-volatilitás rejtett állapot:

$$r_t = \sigma_t \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, 1) \quad (4.29)$$

$$\log \sigma_t^2 = \log \sigma_{t-1}^2 + \eta_t, \quad \eta_t \sim \mathcal{N}(0, \sigma_\eta^2) \quad (4.30)$$

Ez a modell nemlineáris, ezért EKF vagy UKF szükséges a becsléshez. A becsült volatilitás opciók árazására és kockázatkezelésre használható.

Faktor timing: Dinamikus faktor modellekben a faktor-súlyok időben változnak:

$$R_t = \alpha_t + \sum_{k=1}^K \beta_t^k F_t^k + \varepsilon_t, \quad \theta_t = \theta_{t-1} + \eta_t$$

ahol $\theta_t = (\alpha_t, \beta_t^1, \dots, \beta_t^K)^T$. A Kalman-szűrő dinamikus becslést ad a faktor-súlyokra, ami lehetővé teszi a faktorstratégiák időzítését.

Pénzügyi alkalmazás: Opciós árazás és nemlineáris modellek.

Az EKF-ot akkor használjuk, amikor a modell nemlineáris. Például a Black-Scholes modellben az opciós ár nemlineáris függvénye a volatilitásnak. Az EKF segítségével becsülhetjük a volatilitást az opciós árakból (implikált volatilitás becslése).

Egy másik példa a kockázattertek (VaR) becslése nemlineáris portfóliók esetén. Ha a portfólió opciókat vagy más nemlineáris eszközöket tartalmaz, a VaR számítása nemlineáris transzformációt igényel. Az EKF linearizálja ezt a transzformációt, és becslést ad a portfólió kockázatára.

A rezsimváltós modellekben az EKF használható az egyes rezsimekhez tartozó Kalman-szűrők becslésére (rezsim-váltós Kalman-szűrő).

Pénzügyi alkalmazás: Sztochasztikus volatilitás és nemlineáris faktor modellek.

Az UKF előnye, hogy nem igényel Jacobi-mátrixokat, és pontosabb becslést ad erősen nemlineáris rendszerekben. Ez különösen hasznos a következő pénzügyi problémákban:

Sztochasztikus volatilitás modellek: A hozam és a volatilitás közötti kapcsolat nemlineáris (leveredzségi effektus). Az UKF pontosabban becsli a volatilitást, mint az EKF, különösen akkor, ha a volatilitás ugrásszerű változásokat mutat.

Nemlineáris faktor modellek: Ha a faktorok és a hozamok közötti kapcsolat nemlineáris (pl. momentum stratégiák esetén a teljesítmény nemlineárisan függ a faktor értékétől), az UKF jobb becslést ad a faktor-súlyokra.

Opciós árazás: Az opciós ár nemlineáris függvénye az alapul szolgáló eszköz árának és a volatilitásnak. Az UKF segítségével együttesen becsülhetjük az árat és a volatilitást.